



面向上市公司证据驱动研究的 可追溯金融智能体

深藏 Blue 队

2026 年中国研究生金融科技创新大赛参赛作品

版本 1.0 | 2026.08

摘要

大语言模型为上市公司研究提供了新的自动化路径，但现有金融智能体仍面临长周期对话中的上下文漂移、多源异构数据难以协同、生成结论缺乏证据约束等问题。本文设计并实现 **FinTrace**：面向上市公司研究的证据驱动可追溯金融智能体，将金融研究任务转化为可规划、可执行、可校验和可追溯的结构化过程。其主要技术创新包括：

- **证据驱动的研究-验证-生成闭环**：将证据作为核心数据对象，通过统一证据协议关联数据来源、工具结果和最终结论，并在生成前执行证据充分性校验，实现结论可追溯与证据不足时的结构化拒答。
- **可控的金融 Agent Harness**：采用“单一主 Agent + 专业确定性工具”架构，基于 LangGraph 组织任务规划、参数校验、工具执行、结果验证和受控重试，并通过 Schema 约束工具输入输出，提高复杂任务执行的稳定性与可审计性。
- **多源时序证据体系**：将公告、研报等文本构建为可追溯知识库，并与财务报表、股权快照等结构化数据协同；引入统一时间约束研究时点，避免信息泄漏。
- **多工具组合式公司研究**：构建文档检索、财务分析、股权分析和事件因果分析等工具供动态规划组合调用，支持跨报表风险分析、股权穿透、事件演化及证据交叉验证。

FinTrace 采用模块化数据管线、Pydantic 数据契约、FAISS/SQLite 索引、LangGraph Agent Harness 及 CLI/FastAPI 服务接口，形成从金融数据处理到智能体执行的完整技术链路。未来将进一步接入实时行情、宏观指标和新闻舆情数据，完善长期记忆与深层股权图谱，并通过长上下文、故障注入和专家评测持续提升系统的可靠性与复杂金融研究能力。

关键词 金融智能体，上市公司研究，证据驱动，可追溯生成，Agentic AI，工具调用

目录

1	引言	1
1.1	研究背景与关键问题	1
1.2	FinTrace 总体解题思路	1
1.3	主要技术贡献	1
2	FinTrace 智能体架构与执行机制	2
2.1	总体技术架构	2
2.2	从请求解析到有界调查	2
2.3	长周期记忆、动态路由与受控自纠错	3
3	核心金融研究能力及其工具化实现	3
3.1	金融数据底座与统一表示	3
3.2	文档检索与事件研究	4
3.3	财务分析与风险识别	4
3.4	股权关系与穿透分析	4
3.5	多工具协同研究	5
4	可信回答与全链路可追溯机制	5
4.1	统一证据对象与 Evidence Ledger	5
4.2	金融信息的时间一致性约束	6
4.3	Evidence Review 与 Evidence-to-Claim	6
4.4	结构化回答状态与拒答	6
4.5	执行 Trace 与全过程审计	7
5	实验设计与结果	7
5.1	实验设置	7
5.1.1	评测数据与数据划分	7
5.1.2	系统配置与可复现设置	8
5.1.3	统一判定原则	8
5.2	实验一：长周期多轮 Agent 能力	8

5.2.1	实验目的与流程	9
5.2.2	结果展示	9
5.3	实验二：动态路由与受控自纠错	9
5.3.1	动态路由实验	10
5.3.2	故障注入与恢复实验	10
5.4	实验三：股权关系与事件研究	11
5.4.1	股权关系实验	11
5.4.2	事件时间线实验	11
5.5	实验四：财务风险识别与解释	12
5.5.1	风险识别实验	12
5.5.2	专家盲评	12
5.6	实验五：长上下文压力测试	13
5.6.1	压力集构造	13
5.6.2	运行与评价	14
5.7	实验六：关键机制消融	14
5.8	结果分析与报告原则	14
6	工程落地与展望	15
6.1	工程实现与部署	15
6.2	应用与落地可行性	15
6.3	局限性与未来工作	16
6.4	结论	16

1 引言

1.1 研究背景与关键问题

随着大语言模型在自然语言理解、任务规划和工具调用方面能力提升，金融信息服务正由关键词检索和单轮问答逐步转向能够执行连续研究任务的智能体系统。上市公司研究天然涉及公告、研报、财务报表、股权关系和事件信息等多类数据，并要求在连续追问中保持主体、时间和分析口径一致，因此是 **Agentic AI** 的典型应用场景。

然而，通用大模型或简单检索增强生成仍难以直接满足真实研究需求：长周期对话容易出现主体与期间漂移；文本、数值和关系数据难以通过单一检索链路协同；财务计算、时间过滤和关系搜索若完全交由模型自由推理，容易产生不可复现错误；同时，金融研究还具有严格的信息披露时点约束，若混用未来数据，会形成事实上的“时间穿越”。因此，金融智能体不仅要能够回答问题，还需要保证研究过程可控、结论有据且能够审计。

1.2 FinTrace 总体解题思路

系统采用单一主 **Agent** 与专业确定性工具协同的架构：**Agent** 负责请求理解、复杂任务的下一步调查决策和最终解释；工具负责文档检索、财务计算、关系查询和事件整理；**Evidence** 体系负责将工具结果转化为统一、可追溯的事实对象。

在线执行不采用一次性生成完整工具计划，也不采用无限 **ReAct**。系统先恢复会话并解析实体、时间和任务，再进行 **Pre-Answerability** 判断；简单且无歧义的事实请求走确定性 **Direct Fast Path**，复杂研究任务进入 **Evidence-guided Bounded Investigation**，根据当前证据缺口逐步决定下一项工具动作。每个动作均需经过 **Schema** 与能力边界校验，工具执行后再审查 **Evidence** 是否充分，并据此继续调查、部分回答或停止。

1.3 主要技术贡献

本文围绕上市公司研究中的可信执行形成四项主要工作：

- 构建以 **Evidence Ledger** 为核心的证据驱动研究闭环，使工具结果、证据与最终 **Claim** 之间形成显式映射；
- 设计包含可回答性 **Gate**、确定性快速路径和有界调查循环的金融 **Agent Harness**，提高工具调用的稳定性与可审计性；
- 建立统一主体与时间语义下的多源金融数据体系，区分业务观察时点与信息可得截止时点；
- 将文档检索、财务分析、股权分析和事件时间线工具化，并支持 **Agent** 根据研究目标进行组合调用。

2 FinTrace 智能体架构与执行机制

2.1 总体技术架构

FinTrace 采用 “**LangGraph 确定性编排骨架 + Direct Fast Path + Evidence-guided Bounded Investigation**” 的混合架构。系统不让多个大模型角色自由协商，而是由单一主 Agent 负责复杂语义判断和下一步调查决策，将检索、计算、图搜索、时间过滤和停止条件交给确定性程序。

表 1: FinTrace 总体架构分层

层次	主要职责
交互层	通过 CLI、FastAPI 及后续 Web 界面接收问题并返回回答与 Trace。
Agent Harness	会话恢复、请求解析、可回答性判断、路由、动作校验、有界调查、证据审查与回答生成。
金融工具层	提供文档检索、财务分析、股权分析和事件时间线等可独立测试能力。
数据与索引层	管理标准化金融数据、Document/Chunk、SQLite、FAISS 与 BM25 索引。
可信机制	Evidence Ledger、时间约束、结构化状态、Trace 与 Evaluation 贯穿完整链路。

这种分层使大模型、工具和数据保持松耦合。只要遵守统一 Schema，底层数据源、检索器或模型均可独立替换，而无需重构整个 Agent 工作流。

2.2 从请求解析到有界调查

FinTrace 的端到端执行链路如下：

Load Session → Resolve Request → Pre-Answerability → Route Mode → Action → Tool
→ Evidence Review → Answer / Continue

首先，系统从 Session 中恢复近期对话、结构化上下文和已验证发现，并将自然语言请求解析为主体、人物、期间、指标、任务类型和约束。该阶段只负责回答“用户在问什么”，不直接选择工具。

随后执行 Pre-Answerability 判断，将请求分为三类：必要槽位缺失时返回 `clarification_required`；当前系统不存在相应工具、数据源或权限时返回 `unsupported`；其余请求进入路由。对于唯一、参数完整且几乎无歧义的事实型任务，Direct Gate 直接构造确定性 Action；复杂研判则进入 Investigation，由 Planner 根据现有 Evidence 和尚未覆盖的研究方面选择下一步最有价值的动作。

每个 Action 在执行前都要经过参数、能力范围、时间截止和重复调用等校验。工具执行完成后，结果中的 Evidence 合并进入 Evidence Ledger，再由 Evidence Review 判断当前状态是 `sufficient`、`partial` 还是 `insufficient`。若证据缺口仍可通过已有能力补足，系统继续规划下一步；否则进

入部分回答或证据不足状态。 workflow 同时设置最大调查步数和总工具调用上限，使自主调查始终可终止。

2.3 长周期记忆、动态路由与受控自纠错

长周期研究采用四层记忆：近期原始消息用于解析局部指代；结构化 `CurrentContext` 保存当前公司、人物、期间、主题和比较对象；滚动摘要压缩较早对话；经过工具证据验证的历史发现进入 `Verified Findings`。只有具备 `Evidence` 支持的事实才能写入长期已验证记忆，模型猜测和失败结果不会被固化。

因此，累计达到 0.5M Tokens 的历史并不意味着每轮将全部文本重新输入模型。系统仅检索当前任务需要的近期窗口、结构化状态、摘要和已验证事实，以控制上下文成本并减少无关信息干扰。

动态路由也从“关键词选工具”升级为“能力边界内的调查决策”。简单请求优先走高精度 `Direct Gate`；复杂请求由 `Planner` 逐步选择动作，并利用 `Evidence Gap` 决定是否继续调查。若动作参数不合法，可进入有限修复或重新规划；工具临时失败可在既定边界内重试；不可恢复的数据缺失和能力缺口则停止继续猜测。原始动作、校验错误、修复、工具结果、证据缺口和终止原因均写入 `Trace`，为后续工具调用 `Precision` 和自纠错评测提供直接依据。

3 核心金融研究能力及其工具化实现

FinTrace 将上市公司研究中的复杂任务拆解为若干可独立验证的专业能力。系统先对金融数据进行标准化表示，再由确定性工具完成检索、计算、关系查询和事件组织，最后将结构化结果与 `Evidence` 返回 `Agent`。由此，大模型主要承担研究意图理解和跨工具综合，而事实提取与精确计算仍由程序完成。

3.1 金融数据底座与统一表示

公告与研报等非结构化文本统一构建为 `Document`，并进一步切分为可追溯 `Chunk`；财务报表与股东快照则保留结构化字段。不同数据通过统一证券主体、日期语义和 `Evidence` 协议进入工具层。

Raw Data → Normalized Data → Document / Structured Facts → Index → Financial Tools

`Document` 保存文档类型、公司标识、标题、发布日期、正文和来源定位；`Chunk` 保留 `document_id`、章节语义与字符偏移，使检索结果能够反向定位原始材料。结构化数据则按公司、报告期、观察日期和信息截止日期执行精确查询。

表 2: 数据、工具与研究任务映射

数据类型	核心工具	主要研究任务
公告与研报	Document Search	原文检索、监管事项和机构观点查证
公告及事件数据	Event Timeline	事件筛选、聚类、排序与演化重构
三张财务报表	Financial Analysis	指标查询、跨期比较、跨表勾稽与风险识别
股东快照与关系数据	Ownership Analysis	股东查询、持股变化、集中度与关系研究

3.2 文档检索与事件研究

`document_search` 面向公告和研报执行公司、文档类型和日期过滤，并组合 BM25 与向量检索。BM25 保证公司名、财务术语和监管文件等精确词项的稳定召回，向量检索补充语义相近表达；Hybrid 模式融合两路候选，并限制单篇文档重复返回过多 Chunk。每个命中片段均转换为带原始来源定位的 Evidence。

`event_timeline` 用于回答“某家公司一段时间内发生了什么”。工具按公司、事件类型和时间过滤记录，并对相近事件进行聚类和排序，使研究由单篇公告检索扩展为事件序列重构，适用于监管处罚、重大事项变化和持续风险跟踪等任务。

3.3 财务分析与风险识别

财务任务具有明确的数值和期间约束。FinTrace 将指标读取、同比/跨期比较、跨表勾稽和风险规则封装为 `financial_analysis`，避免让大模型直接从长报表中抄数并心算。工具以统一指标目录连接资产负债表、利润表和现金流量表，并校验累计口径指标的期间可比性。

在风险研究中，系统可联合观察营业收入、净利润、经营现金流、应收账款、存货和负债等指标，识别利润与现金流背离、应收或存货异常扩张及偿债压力等风险信号。风险信号仅作为进一步查证的触发器，并不直接等价于财务造假或投资结论；Agent 可继续调用 Document Search 查找审计意见、监管问询或公司解释进行交叉验证。

3.4 股权关系与穿透分析

`ownership_analysis` 将主要股东快照组织为时序关系数据，可按观察时点查询主要股东、反查股东持有的上市公司，并比较不同快照之间的进入、退出、增持和减持。对于数据中能够可靠连接的主体，可进一步在增强关系图中执行有限深度路径搜索，并要求每一跳关系均绑定对应 Evidence。

股权分析始终显式保留数据边界。主要股东快照不能天然证明完整实际控制关系，非主要股东、非上市主体、协议控制和一致行动关系需要额外数据补充，因此系统只对现有证据能够支持的路径做出陈述。

3.5 多工具协同研究

FinTrace 的核心能力不是四个孤立接口，而是根据 Evidence Gap 逐步组合工具。例如综合风险研究可以先由 Financial Analysis 发现异常，再通过 Document Search 查证相关披露，使用 Event Timeline 重构事件演化，并在必要时调用 Ownership Analysis 检查股东变化。

Plan Next Action → Retrieve / Calculate / Trace → Evidence Review → Next Action
or Conclusion

这种模式将传统 RAG 的“检索文本—生成答案”扩展为证据驱动连续调查：每一步动作由当前问题与已有证据共同决定，直到关键方面被覆盖或系统确认剩余缺口无法可靠补足。

4 可信回答与全链路可追溯机制

FinTrace 面向金融研究场景对回答的可靠性、时效性和可验证性提出了更严格的要求。金融问题的回答通常不仅涉及某一项数据的查询，还可能同时涉及财务指标、股东关系、公告事件和研究观点等不同类型的信息。如果仅依赖大语言模型根据已有知识直接生成结论，即使回答在语言层面完整，也难以保证信息来源、数据时点以及结论与事实之间的对应关系。因此，FinTrace 将证据管理和过程追踪作为 Agent 工作流的基础能力，将原始数据、工具执行、证据形成、结论生成以及运行过程纳入统一的可信机制中。

4.1 统一证据对象与 Evidence Ledger

每条 Evidence 具有唯一 evidence_id，保存证据类型、来源、结构化事实、支持强度和使用关系。其核心字段如表 3 所示。

表 3: Evidence 核心字段

字段	含义
evidence_id	唯一证据标识，用于回答引用、日志与评测对齐
evidence_type	文档、财务事实、持股关系、事件等证据类型
source	Document、公司、页码/行号或数据路径等来源定位
fact	工具提取、查询或确定性计算得到的结构化事实
support_level	direct、derived 或 weak 支持强度
used_by	记录产生或使用该证据的工具动作

工具执行后，Evidence 按 evidence_id 合并进入 Evidence Ledger。原始来源、工具结果和自然语言 Claim 因而形成：

Source → Tool Result → Evidence → Evidence Ledger → Claim

4.2 金融信息的时间一致性约束

金融研究必须区分“研究哪个时点”和“当时已经知道什么”。FinTrace 使用两个互补时间变量：

- **as_of_date**: 业务观察时点，用于确定目标公司的状态、股东快照或事件区间；
- **knowledge_cutoff**: 信息可得截止时点，用于限制该次研究允许使用的最晚公开信息。

因此，系统中的“最新”表示在给定 **knowledge_cutoff** 下已经披露的最新有效记录，而不是数据库中的全局最新数据。该约束用于降低 look-ahead bias，避免利用未来披露信息解释历史问题。

4.3 Evidence Review 与 Evidence-to-Claim

工具执行后，FinTrace 对当前证据进行 Post-Answerability 审查。Evidence Review 记录已经覆盖的研究方面与 Evidence Gap，并将证据状态划分为：

- **sufficient**: 当前证据足以覆盖所需研究方面，可生成完整回答；
- **partial**: 部分方面已有证据，其余无法继续可靠补足，生成部分回答并说明限制；
- **insufficient**: 没有获得能够支持回答的有效证据，返回证据不足。

若 Evidence Gap 可由现有能力解决，复杂任务不会立即生成答案，而是返回 Investigation Loop 规划下一项动作。最终自然语言生成只允许使用工具结果、Evidence 和已记录限制，逻辑上要求

$$\text{Claim} \subseteq \text{Supported}(\text{Evidence Ledger}).$$

模型可以归纳多条证据，但不能凭参数知识补充金额、比例、时间、持股关系或事件细节。财务异常也只能描述为风险信号，除非存在额外证据支持更强结论。

4.4 结构化回答状态与拒答

FinTrace 将“不能回答”的原因进一步拆分为不同运行状态：

表 4: 主要回答状态及含义

状态	含义
answered	已获得充分证据并完成回答
partially_answered	仅部分问题获得充分证据
clarification_required	用户输入缺少必要主体、日期或比较条件
unsupported	当前系统不存在所需工具、数据源或权限
insufficient_evidence	能力存在，但本次实际证据不足
failed	工具、模型、网络或程序执行失败

这种区分避免将“用户条件不足”“能力不存在”“证据没找到”和“程序失败”混为同一种拒答，也为离线评测和失败归因提供了稳定标签。

4.5 执行 Trace 与全过程审计

每次运行记录 Parsed Request、Pre-Answerability、Routing Mode、Planner Action、工具结果、Evidence ID、Evidence Gap、动作修复、模型调用、Answer Status、Termination Reason、错误与延迟等信息。完整审计链为：

Query → Parsed Request → Action → Tool Result → Evidence → Review → Final Answer

因此，当最终结果出现问题时，可以进一步判断错误来自请求解析、Direct Gate/Planner 路由、工具数据、Evidence Gap 还是回答生成，而不是将所有失败笼统归因于“大模型幻觉”。同一 Trace 也可直接用于工具调用 Precision、自纠错成功率和证据覆盖率等评测。

5 实验设计与结果

为验证 FinTrace 在长周期对话、工具决策、金融专项研究与可信回答方面的实际能力，本章将赛题要求拆解为六组相互独立的实验。每组实验均明确数据构造、运行流程、评价标准与结果展示方式，并在固定代码、模型、Prompt 和数据快照下重复执行。除特别说明外，所有“实测值”均在正式评测完成后填写，不以开发阶段局部样本代替最终结果。

5.1 实验设置

5.1.1 评测数据与数据划分

多轮 Agent 实验使用赛题提供的 35 个 Session、1,410 个 Turn。为避免在评测集上反复调整规则与 Prompt，建议以 Session 为单位进行划分：7 个 Session 用作开发集，剩余 28 个 Session 作为冻结测试集；划分时尽量保持会话长度、任务类型和工具需求的分布一致。若赛事后续提供独立隐藏测试集，则本地划分仅用于开发和消融，正式成绩以隐藏测试集为准。

金融专项评测在现有数据基础上构造独立金标集。推荐规模如表 5 所示。若某类真实数据无法满足目标数量，则使用全部可验证样本，并在结果中报告实际样本数，不通过重复样本补足规模。

所有自动评测样本至少保存以下金标字段：query、目标实体、时间条件、Gold Facts、期望 Capability/Tool、允许工具集合、Evidence ID、Answerability 以及必要时的 Gold Path 或 Gold Events。评测脚本只读取冻结金标，不允许在运行中向 Agent 暴露答案信息。

表 5: FinTrace 实验数据集设计

实验数据集	建议规模	构造原则
多轮 Agent 测试集	28 Sessions	保持原始 Turn 顺序，覆盖跨轮指代、期间切换、主题切换与连续研究
路由基准集	240 Questions	单工具事实型与多阶段调查型各约一半，人工标注允许调用的 Capability/Tool
故障注入集	120 Cases	参数错误、必要槽位缺失、Tool 临时失败、Action 校验失败各约 30 例
股权关系集	约 90 Queries	一跳、两跳、三层及以上路径尽量分层采样
事件时间线集	约 80 Queries	人工标注关键事件、日期、类型与来源文档
财务风险集	≥ 200 Company-Periods	对主要风险类型进行人工或规则复核后形成多标签金标
专家盲评集	50 Reports	从综合财务研究任务中分层抽取，隐藏系统内部信息后交由专家评分
长上下文压力集	240 Runs	12 个锚点任务 $\times$ 4 个历史长度 $\times$ 5 个事实位置

5.1.2 系统配置与可复现设置

正式实验前冻结 FinTrace 代码版本，并记录模型、Prompt、索引和运行参数。推荐统一记录表 6 中的配置。

对于随机性可能影响结果的 LLM 调用，正式测试使用固定 Temperature，并在同一配置下运行。若需考察随机波动，可在附加实验中对同一测试集重复运行 3 次，并报告均值与标准差；主要竞赛指标仍以预先规定的一次固定配置运行作为主结果。

5.1.3 统一判定原则

实验采用“事实正确 + 工具正确 + 证据可追溯”的联合评价原则。对于可回答问题，若最终回答包含关键事实错误或无证据的重要 Claim，则该样本不能判为完全正确；对于不可回答问题，则不要求模型强行给出实体答案，而检查其是否正确输出 clarification_required、unsupported 或 insufficient_evidence 等状态。

5.2 实验一：长周期多轮 Agent 能力

表 6: 实验运行配置记录项

配置项	记录内容
FinTrace 版本	Git Commit SHA / Release Version
LLM	模型名称、API 版本、Temperature、必要的推理参数
Prompt	Request Parser、Planner、Evidence Reviewer、Final Answer 等 Prompt 版本
Agent 上限	max_steps、max_total_tool_calls、Action Repair 上限
数据版本	标准化数据快照、Document/Chunk 版本、财务/股权/事件索引版本
时间约束	默认 knowledge_cutoff 与样本级时间条件
运行环境	CPU、内存、操作系统及必要软件版本

5.2.1 实验目的与流程

该实验验证 FinTrace 在连续金融研究中的实体继承、时间继承、历史事实记忆与最终回答正确性。测试以 Session 为单位执行，整个 Session 固定同一 session_id，并严格按照原始 Turn 顺序逐轮回放。

在第 t 轮运行时，Agent 仅允许访问第 1 至 $t-1$ 轮已经产生的会话状态、滚动摘要和 Verified Findings，不得读取任何后续问题或金标。每轮调用完整 run_agent() workflow，并保存 ParsedRequest、RoutingMode、Action、ToolResult、Evidence、AnswerStatus 和 FinalAnswer。

评测脚本随后将最终回答与 Gold Facts 对齐。关键事实 Recall 定义为

$$\text{FactRecall} = \frac{\sum_i |\hat{F}_i \cap F_i|}{\sum_i |F_i|},$$

其中 F_i 为第 i 个样本的 Gold Facts， $\hat{F}_i$ 为回答中被正确恢复且得到证据支持的事实集合。

样本级回答准确率采用严格判定：对于可回答样本，要求核心 Gold Facts 均被正确覆盖、无关键事实错误且回答状态合理；对于不可回答样本，则要求输出正确的结构化状态。

5.2.2 结果展示

结果按问题类型分别报告，以避免总体平均值掩盖跨轮任务难度。

除表格外，还应对错误样本进行 Trace 归因，分别统计请求解析错误、上下文恢复错误、工具错误、证据不足与最终生成错误的占比。

5.3 实验二：动态路由与受控自纠错

表 7: 长周期多轮 Agent 评测结果

问题类型	样本数	回答准确率	关键事实 Recall
单轮事实查询	—	—	—
跨轮指代与实体继承	—	—	—
跨期间比较	—	—	—
主题切换后继续追问	—	—	—
多阶段连续研究	—	—	—
总体	—	$\geq 90\%$	$\geq 90\%$

5.3.1 动态路由实验

路由基准集中的每个问题预先标注 **Expected Capability**、允许工具集合、必要主体与时间参数，并标记 **Direct** 与 **Investigation** 中哪些执行方式可接受。评测时运行完整 Agent，并从 Trace 读取实际 Action 和 ToolCall。

一条工具调用只有同时满足以下条件才记为正确：工具属于该样本允许集合；主体、期间等关键参数正确；调用并非无必要重复。Tool Call Precision 定义为

$$\text{ToolPrecision} = \frac{N_{\text{correct calls}}}{N_{\text{all calls}}}.$$

Direct Fast Path 另外报告 Coverage，即实际进入 **Direct** 路由的样本占全部可路由样本的比例。该指标不追求越高越好，重点是验证其高精度特性。

表 8: 动态工具路由实验结果

路由方式	Precision	Coverage	平均 Tool Calls
Direct Fast Path	—	—	—
Investigation	—	—	—
Overall	$\geq 92\%$	—	—

5.3.2 故障注入与恢复实验

自纠错实验不依赖自然发生的偶发错误，而使用故障注入器对正常请求构造可重复故障。具体方式如下：

恢复成功要求最终结果与同一请求的无故障基线一致，且没有超过系统预设最大调查步数和工具调用上限。恢复率定义为

$$\text{RecoveryRate} = \frac{N_{\text{successfully recovered}}}{N_{\text{recoverable cases}}}.$$

表 9: 自纠错实验的故障注入方式

故障类型	注入方法	期望恢复动作
参数格式错误	将合法日期、列表或枚举参数替换为非法格式	Action Repair
必要槽位缺失	删除公司、期间、比较对象等必要参数	Clarification / Re-plan
Tool 临时失败	第一次调用强制返回 <code>retryable=true</code> , 后续恢复正常	Controlled Retry
Action 校验失败	构造超出 Capability 或违反时间约束的 Action	Repair / Replan

表 10: 不同故障类型下的恢复结果

故障类型	样本数	恢复成功率	平均额外调用数
参数格式错误	30	—	—
必要槽位缺失	30	—	—
Tool 临时失败	30	—	—
Action 校验失败	30	—	—
总体	120	≥ 80%	—

对于数据源无覆盖、系统能力不存在等不可恢复问题，不计入 Recovery Rate，而单独统计是否正确停止调查并返回对应 AnswerStatus。

5.4 实验三：股权关系与事件研究

5.4.1 股权关系实验

股权金标由经过人工复核的关系数据生成。首先从可验证的关系图中采样起点公司与目标主体，并保存标准路径；随后按一跳、两跳和三层及以上路径分层构造自然语言查询。若真实数据中的三层路径数量不足，则使用全部可验证三层路径并如实报告样本规模。

一条返回路径只有同时满足实体、边方向、关键持股比例、有效时间和 Evidence 来源均与 Gold Path 一致时，才记为端到端正确。除比赛要求的 Path Exact Match 外，可辅助报告 Entity Accuracy 和 Edge Accuracy，以定位错误发生在哪一层。

5.4.2 事件时间线实验

事件金标由人工阅读相关公告及已有事件记录后建立，每个 Gold Event 至少包含 event_id、事件日期、事件类型、关键实体和来源文档。系统对指定公司与时间区间生成 Timeline 后，将预

表 11: 股权关系分析实验结果

路径复杂度	样本数	Entity Acc.	Path Exact Match	P95 时延 / s
一跳关系	—	—	—	—
两跳关系	—	—	—	—
三层及以上路径	—	—	≥ 85%	—
整体查询与结果组装	—	—	—	≤ 5

测事件与 Gold Event 按事件类型、主体和日期进行匹配。

若事件使用明确公告日期，则要求日期精确匹配；若事件语义对应实际发生日期但披露日期存在差异，则在标注阶段预先固定匹配口径，不在评测时临时调整。事件 Recall 定义为正确召回的 Gold Event 占全部 Gold Event 的比例，同时统计事件排序正确率和聚类准确率。

表 12: 事件时间线实验结果

指标	目标值	实测值
关键事件节点 Recall	≥ 85%	—
时间排序正确率	—	—
事件聚类准确率	—	—

5.5 实验四：财务风险识别与解释

5.5.1 风险识别实验

以公司—报告期为最小样本单位，对利润与经营现金流背离、应收账款异常增长、存货异常积压和偿债压力等风险建立多标签金标。金标由确定性计算结果与人工复核共同形成，避免直接使用待评测系统本身的规则输出作为唯一真值。

对于每一种风险类型分别计算 Precision、Recall 和 F1：

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}, \quad F_1 = \frac{2PR}{P + R}.$$

总体指标采用各风险类型 F1 的宏平均值。

5.5.2 专家盲评

从综合财务研究任务中分层抽取 50 份系统报告，去除模型名称、内部状态和实验标签后随机打乱顺序，由 3 名具有金融、会计或相关研究背景的评审者独立评分。每个维度采用 1–5 分制，建议评价事实正确性、证据充分性、跨报表分析完整性和限制说明规范性。

表 13: 不同财务风险类型的识别结果

风险类型	Precision	Recall	F1
利润与经营现金流背离	—	—	—
应收账款异常增长	—	—	—
存货异常积压	—	—	—
偿债压力	—	—	—
Macro Average	—	—	≥ 85%

若一份报告四个维度的平均分不低于 4.0，且“事实正确性”平均分不低于 4.0，则判定为“优秀”。专家优秀率定义为优秀报告数量占全部盲评报告的比例；同时报告评审者之间的一致性指标，以避免单一专家偏好主导结果。

表 14: 财务分析报告专家盲评结果

评价维度	平均得分	标准差	优秀样本占比
事实正确性	—	—	—
证据充分性	—	—	—
跨报表分析完整性	—	—	—
限制与风险表述规范性	—	—	—
综合评价	—	—	≥ 80%

5.6 实验五：长上下文压力测试

5.6.1 压力集构造

长上下文实验不采用简单复制无关文本的方式扩展长度，而以真实多轮会话为骨架，在历史中插入经过标注的早期关键事实、相关金融文本、相似公司和相似数值干扰。选择 12 个具有明确 Gold Fact 的锚点任务，对每个任务构造

50K, 100K, 200K, 500K Tokens

四档累计历史，并将关键事实分别放置在约 5%、25%、50%、75% 和 95% 的历史位置，形成 $12 \times 4 \times 5 = 240$ 个可控测试实例。

每个实例保持最终问题和 Gold Facts 不变，仅改变历史长度与关键事实距离，从而区分“历史更长”和“事实更远”两种因素。干扰文本优先从真实公告、研报和其他公司会话中采样，且不得直接泄露最终答案。

5.6.2 运行与评价

测试时仍通过正常 Session Memory 机制逐步写入历史，不直接将构造后的完整文本一次性塞入最终 Prompt。系统记录累计历史 Token 数、实际送入模型的 Prompt Token 数、Fact Recall、Answer Accuracy 和 Tool Call Precision。

正式结果建议至少绘制以下两类曲线：

- 历史 Token 数与 Fact Recall / Answer Accuracy 的关系；
- 累计历史 Token 数与实际 Prompt Token 数的关系。

第一类曲线用于观察长历史性能退化，第二类曲线验证分层记忆是否真正控制了模型上下文规模。

5.7 实验六：关键机制消融

消融实验固定同一测试样本、模型、Prompt、数据和运行参数，仅改变一个目标模块。设置：

- **Full FinTrace**：完整启用分层记忆、Direct/Investigation 路由、专业工具与 Evidence Review；
- **w/o Structured Memory**：移除结构化 CurrentContext 与 Verified Findings，仅保留近期消息和滚动摘要；
- **w/o Evidence Review**：保留 ToolResult，但取消 Evidence Gap 驱动的充分性审查及对应 AnswerStatus 约束。

结构化记忆消融在长上下文压力集上评测，重点比较 Fact Recall、Answer Accuracy 和 Tool Precision；Evidence Review 消融在多轮与专项综合研究集上评测，重点统计无证据 Claim 率、错误作答率和过早结束调查比例。

表 15: FinTrace 关键机制消融实验

系统版本	Fact Recall	Answer Accuracy	Tool Precision	无证据 Claim 率
Full FinTrace	—	—	—	—
w/o Structured Memory	—	—	—	—
w/o Evidence Review	—	—	—	—

若某项消融导致性能下降，应进一步利用 Trace 判断其主要影响是上下文恢复、工具路由还是最终回答约束，从而避免仅凭总体分数解释模块贡献。

5.8 结果分析与报告原则

不同实验分别在所属小节中报告结果，不再将全部指标压缩到一张总表。最终综合分析仅回答三个问题：其一，FinTrace 是否能够在长周期会话中稳定保持主体、时间和关键事实；其二，Direct/Investigation 与专业工具是否达到赛题要求的 Tool Precision、股权路径准确率、事件 Recall、财

务风险 F1 和时延指标；其三，结构化记忆与 Evidence Review 是否能够显著降低无依据生成并提升长历史可靠性。

对于未达到目标的指标，应结合 Trace 将失败归因至请求解析、路由决策、工具算法、数据覆盖、Evidence Gap 或最终回答生成，并在后续版本中针对相应模块进行修正。

6 工程落地与展望

FinTrace 强调可运行、可复现和可扩展的工程实现。项目采用模块化 Python 架构，将用户入口、Agent Harness、金融工具、数据处理、Prompt、评测和部署相互解耦，使单个模块能够独立测试和替换。

6.1 工程实现与部署

表 16: FinTrace 主要工程组件

组件	主要用途
LangGraph	Agent 状态流转、条件分支与有界调查
Pydantic	请求、Action、ToolResult、Evidence 等数据契约
SQLite / FAISS / BM25	结构化查询、向量检索与关键词检索
NetworkX	关系图与路径分析
FastAPI / Uvicorn	标准化 HTTP 服务接口
PyMuPDF / python-docx	公告与报告等文档处理
Pytest	工具、工作流与回归测试

系统同时支持本地 CLI 与 FastAPI。CLI 可直接调用核心 `run_agent()`，适合开发和现场演示；FastAPI 将同一 Agent 封装为 HTTP 服务，便于 Web 前端或外部应用复用。模型接口采用 OpenAI-compatible 形式封装，Prompt 则按请求解析、动作规划、证据审查、动作修复和最终生成等职责版本化管理。

6.2 应用与落地可行性

FinTrace 不依赖重新训练专用金融大模型，而是利用通用模型完成语义理解、调查决策和解释，将财务计算、关系搜索和时间过滤交由确定性工具，因此能够以较低训练成本持续迭代。数据、工具和模型均通过统一 Schema 解耦，后续可逐步替换数据源、Embedding、语言模型或检索索引。

面向个人投资者时，系统可用于公司事实查证、风险线索整理和研究辅助；面向专业场景时，可进一步接入授权金融数据库、内部研究资料和更完整的知识图谱。应用层可以扩展，但核心边

界不变：模型负责组织研究过程，关键金融事实必须由工具和 Evidence 支持。

6.3 局限性与未来工作

当前系统仍受数据覆盖和研究边界限制。公开主要股东数据不足以独立恢复全部实际控制关系；实时行情、宏观指标与完整新闻舆情仍需外部接口补充；长期记忆和复杂调查策略需要在更大规模真实会话中持续验证；财务风险规则也只能提供进一步核查线索，不能替代审计结论或投资决策。

后续将重点扩展实时金融 API 与新闻舆情、补充非上市主体及控制关系数据、完善跨 Session 长期研究记忆，并加强 Claim-level 自动核验与来源冲突检测。

6.4 结论

本文提出 **FinTrace**，一套面向上市公司研究的证据驱动可追溯金融智能体。系统通过可回答性 Gate、确定性快速路径与有界调查，将多源金融数据、专业工具和 Evidence Ledger 组织为可执行、可验证和可审计的研究过程。FinTrace 的目标不是让大模型记住更多金融事实，而是使其能够在明确能力边界内选择正确的调查动作，并让最终结论始终受数据、时间和证据约束。随着评测、实时数据与关系图谱进一步完善，该架构可继续扩展为面向个人投资者和研究人员的可信金融研究辅助系统。