



面向上市公司证据驱动研究的 可追溯金融智能体

深藏 Blue 队

2026 年中国研究生金融科技创新大赛参赛作品

版本 1.0 | 2026.08

摘要

大语言模型为上市公司研究提供了新的自动化路径，但现有金融智能体仍面临长周期对话中的上下文漂移、多源异构数据难以协同、生成结论缺乏证据约束等问题。本文设计并实现 **FinTrace**：面向上市公司研究的证据驱动可追溯金融智能体，将金融研究任务转化为可规划、可执行、可校验和可追溯的结构化过程。其主要技术创新包括：

- **证据驱动的研究-验证-生成闭环**：将证据作为核心数据对象，通过统一证据协议关联数据来源、工具结果和最终结论，并在生成前执行证据充分性校验，实现结论可追溯与证据不足时的结构化拒答。
- **可控的金融 Agent Harness**：采用“单一主 Agent + 专业确定性工具”架构，基于 LangGraph 组织任务规划、参数校验、工具执行、结果验证和受控重试，并通过 Schema 约束工具输入输出，提高复杂任务执行的稳定性与可审计性。
- **多源时序证据体系**：将公告、研报等文本构建为可追溯知识库，并与财务报表、股权快照等结构化数据协同；引入统一时间约束研究时点，避免信息泄漏。
- **多工具组合式公司研究**：构建文档检索、财务分析、股权分析和事件因果分析等工具供动态规划组合调用，支持跨报表风险分析、股权穿透、事件演化及证据交叉验证。

FinTrace 采用模块化数据管线、Pydantic 数据契约、FAISS/SQLite 索引、LangGraph Agent Harness 及 CLI/FastAPI 服务接口，形成从金融数据处理到智能体执行的完整技术链路。未来将进一步接入实时行情、宏观指标和新闻舆情数据，完善长期记忆与深层股权图谱，并通过长上下文、故障注入和专家评测持续提升系统的可靠性与复杂金融研究能力。

关键词 金融智能体，上市公司研究，证据驱动，可追溯生成，Agentic AI，工具调用

目录

1	引言	1
1.1	研究背景与关键问题	1
1.2	FinTrace 总体解题思路	1
1.3	主要技术贡献	1
2	FinTrace 智能体架构与执行机制	2
2.1	总体技术架构	2
2.2	从请求解析到有界调查	3
2.3	长周期记忆、动态路由与受控自纠错	4
2.4	Evidence 约束与可追溯回答机制	6
3	核心金融研究能力及其工具化实现	7
3.1	金融数据底座与统一表示	8
3.2	文档检索与事件研究	8
3.3	财务分析与风险识别	9
3.4	股权关系与穿透分析	10
3.5	多工具协同研究	11
4	可信回答与全链路可追溯机制	12
4.1	统一证据对象与 Evidence Ledger	12
4.2	金融信息的时间一致性约束	13
4.3	Evidence Review 与 Evidence-to-Claim	14
4.4	结构化回答状态与拒答	15
4.5	执行 Trace 与全过程审计	16
5	实验设计与结果	17
5.1	实验设置	17
5.1.1	评测任务与数据集	17
5.1.2	模型与运行配置	18
5.1.3	参考标注构建与质量控制	19

5.2	长上下文问答、工具调用与纠错	19
5.2.1	回答质量与工具路由评价方法	19
5.2.2	错误处置与可靠性评价方法	20
5.2.3	长上下文、路由与纠错实验结果	21
5.2.4	运行效率与资源消耗	23
5.3	股权穿透与事件脉络	24
5.3.1	股权穿透完整严格准确率	24
5.3.2	事件节点与事件簇质量	24
5.3.3	专项实验结果与工具性能	25
5.4	财务风险预警与报告质量	26
5.5	综合分析与本章小结	29
6	工程落地与展望	31
6.1	工程实现与部署	31
6.2	应用与落地可行性	31
6.3	局限性与未来工作	32
6.4	结论	32

1 引言

1.1 研究背景与关键问题

金融信息服务正从关键词检索与单轮问答，向连续研究型智能体演进，大语言模型在自然语言理解、任务规划和工具调用上的突破，为这一转变提供了技术支撑。上市公司研究天然涉及公告、研报、财务报表、股权关系和事件信息等多类数据，且在连续追问中必须始终维持主体、时间窗口与分析口径的统一，这对智能体的上下文管理能力构成了现实要求。

然而，尽管技术基础已初步具备，通用大模型或常规检索增强生成方案在真实研究场景中仍暴露出明显不足。问题集中体现在以下几个方面：一是长周期对话中主体和时间窗口容易发生漂移，导致分析基准失准；二是文本、数值与关系数据难以通过同一条检索链路协同处理，信息整合效率低下；三是财务计算、时间过滤和关系搜索若完全依赖模型自由推理，结果往往无法复现，缺乏可验证性；此外，金融研究受信息披露时点的严格约束，混入未来数据会造成事实上的“时间穿越”，这进一步加大了模型输出的风险。

综上，金融智能体不仅需要具备作答能力，更关键的是要确保研究过程全程可控、结论推导有据可依，并且能够满足审计追溯的要求，从而真正服务于专业投资决策场景。

1.2 FinTrace 总体解题思路

FinTrace 的设计遵循一条基本逻辑：大模型负责指引调查方向，程序负责锁定事实内容，而证据则对最终结论形成刚性约束。在此基础上，系统采用单一主 Agent 与专业确定性工具协同的框架——Agent 承担请求理解、复杂任务的调查决策和最终解释，工具负责文档检索、财务计算、关系查询与事件整理，Evidence 层则将所有输出转化为统一且可追溯的事实对象。

在线执行时，系统既不预先编排完整的工具调用计划，也不采用无休止循环的 ReAct 模式。实际流程从恢复会话上下文、解析实体与时间目标开始，随即进入 Pre-Answerability 判断：对明确无误的事实问询直接走快速通道；遇到复杂研究任务，则转入证据驱动的有限调查路径，根据当前证据缺口逐步决定下一步动作。每步操作均须通过 Schema 校验和能力边界检查，工具返回后系统会评估证据是否充足，进而判断是继续深入、给出部分结论还是终止任务。整套机制通过设定清晰的决策节点和校验关卡，确保了过程的可控性和结论的可审计性。

1.3 主要技术贡献

本文围绕上市公司研究中的可信执行，形成以下四项工作：

- **证据驱动研究闭环**：构建以 Evidence Ledger 为核心的证据体系，使工具结果、证据与最终 Claim 之间形成显式映射关系。

- **金融 Agent Harness:** 设计包含可回答性 Gate、确定性快速路径与有界调查循环的执行框架，提升工具调用的稳定性与可审计性。
- **多源金融数据体系:** 建立统一主体与时间语义下的数据组织方式，区分业务观察时点与信息可得截止时点。
- **专业化工具集:** 将文档检索、财务分析、股权分析与事件时间线等功能工具化，支持 Agent 根据研究目标进行组合调用。

2 FinTrace 智能体架构与执行机制

2.1 总体技术架构

面向金融长上下文问答中多轮语义继承、动态工具调用、复杂任务拆解以及事实可追溯等需求，FinTrace 构建了一套以确定性控制流为骨架、以大语言模型为语义决策核心、以专业金融工具为事实执行单元的证据驱动型智能体架构。系统并未采用多个自由智能体相互协商的开放式工作模式，而是将大语言模型的决策空间约束在预先定义的能力边界和状态转换体系之内，使复杂金融问题的处理过程能够被记录、校验和复现。

从整体技术路径看，FinTrace 采用“LangGraph 确定性编排骨架 +Direct Fast Path+Evidence-guided Bounded Investigation”的混合架构。大语言模型主要承担复杂语义理解、任务识别以及下一步调查动作规划，财务计算、股权路径搜索、事件筛选、文档检索、时间过滤和停止条件等确定性任务则由程序及专业工具完成。工具产生的结构化结果经过校验后统一转换为 Evidence，并由 Evidence Ledger 管理，最终回答只能基于已经验证的 Evidence 形成。由此，系统将大语言模型的开放推理能力嵌入可验证的执行框架之中，在保留复杂金融研究能力的同时降低事实性幻觉、错误工具调用和无依据推断的风险。

当前系统以 LangGraph StateGraph 作为在线 Agent 的统一控制骨架。CLI、FastAPI 与 Next.js Web 前端均接入同一套执行工作流，因此本地调试、接口调用、前端演示和后续评测使用相同的状态定义和运行逻辑。工具、数据源与大语言模型之间通过统一 Schema 建立交互契约，只要输入输出协议保持一致，底层检索器、模型或数据索引均可独立更新，而无需重构整个 Agent 控制流程。FinTrace 当前总体架构的主要层次及职责如表 1 所示。

这种分层结构使 FinTrace 不再依赖“大模型直接给出最终答案”的单一生成范式，而是将金融问答转换为一系列具有明确输入、动作、证据和终止条件的可执行任务。交互层负责接收问题，Agent 编排层负责判断下一步应该做什么，专业工具负责回答事实层面的“数据是什么”，Evidence 体系负责判断“这些结果是否足以支持最终结论”。不同层次之间保持职责分离，从而为后续长周期记忆、动态路由和防幻觉机制提供统一技术基础。

表 1 FinTrace 总体架构主要层次及职责

架构层级	主要职责
交互接入层	通过 CLI、FastAPI 与 Next.js Web 前端接收用户请求，并展示回答、工具执行状态、Evidence 与运行 Trace
Agent 编排层	完成会话恢复、请求解析、可回答性判断、任务路由、动作校验、有界调查、证据审查和回答生成
专业工具层	提供财务分析、股权分析、事件时间线、研报观点分析及文档检索五类独立能力
数据与索引层	管理标准化金融数据、股东快照、公告事件、研报观点、Document、Chunk，以及 SQLite、FAISS 和 FTS5/BM25 等索引
可信控制层	通过 Evidence Ledger、Knowledge Cutoff、Action Validation、Trace 和 Evaluation 约束完整执行过程

2.2 从请求解析到有界调查

FinTrace 在接收到用户问题后并不立即调用大语言模型生成结论，而是首先恢复当前 Session 的历史状态，并将自然语言问题转换为可执行的结构化请求。当前在线工作流依次完成会话恢复、请求解析、可回答性判断、任务路由、动作校验、工具执行、工具结果验证、证据合并与证据充分性审查，并根据当前 Evidence 状态决定继续调查或进入最终回答阶段。

请求解析阶段主要解决“用户正在问什么”这一问题。系统综合当前输入与历史上下文识别当前主体、人物、比较对象、时间锚点、时间范围、财务报告期、指标、任务类型、能力缺口及潜在歧义。本轮明确出现的实体与任务优先于历史状态，当用户仅通过简称、股票代码或代词延续上一轮查询时，系统再结合 `current_context` 判断是否存在可以可靠继承的上下文信息。

时间信息在请求解析中被单独处理。系统区分明确日期、今日、最新、近期以及未指定时间等不同语义，并将统一知识截止日作为数据访问边界。知识截止日由程序注入，Planner 无权自行修改，因此可以防止模型在规划过程中使用超出比赛数据范围的未来信息。对于财务任务，报告期还需进一步经过确定性期间解析器转换，以避免大语言模型自行猜测年份、混合不同累计口径或将知识截止日错误地视为财务报告期。

完成解析后，系统执行 Pre-Answerability 判断。当前实现并非简单区分“可以回答”与“不可以回答”，而是进一步划分为四类状态。

这种设计能够避免在能力缺失时将问题错误映射到“最相似”的工具。例如，当一个问题同时包含财务分析和实时股价信息时，系统可以继续完成财务部分，并将实时行情记录为 `capability gap`，而不是因为缺少实时行情接口而放弃整条任务，也不会将行情问题错误路由至财务工具。

在完成可回答性判断后，FinTrace 根据任务复杂程度选择 Direct Fast Path 或 Bounded Investi-

表 2 Pre-Answerability 状态及处理逻辑

状态	判定含义	后续处理
routeable	系统具备相应能力，且执行所需关键参数完整	进入正常路由
routeable_with_gaps	请求包含可执行内容，同时存在非阻断能力缺口	继续调查可支持部分，并在最终回答中披露未覆盖内容
clarification_required	主体、任务或比较对象等关键条件无法唯一确定	暂停工具调用并请求用户补充信息
unsupported	当前系统不存在对应数据或工具能力	明确说明能力边界，不调用无关工具替代

gation。对于实体、时间、指标和操作均能够唯一解析的简单事实请求，Direct Gate 可以直接形成确定性的工具 Action。例如，用户明确询问某公司某一报告期的营业收入时，只要主体、指标与报告期均完成解析，系统即可直接调用对应的财务指标查询操作，从而避免不必要的 Planner 调用。

Direct Fast Path 并不意味着跳过可信控制。即使是简单的确定性调用，其工具结果仍需经过结果合法性检查、Evidence 转换、Evidence Ledger 合并及证据充分性判断后，才能进入最终回答环节。

当问题涉及多步骤调查、多个证据来源或原因追溯时，系统进入 Evidence-guided Bounded Investigation。Planner 在每一轮仅产生一个 AgentAction，并明确本轮需要调用的工具、具体 Operation、执行参数、调用目的和预期获得的 Evidence。工具执行结束后，系统重新评估现有证据是否已经足以覆盖用户问题。若仍存在可以通过当前能力补足的核心信息缺口，则继续规划下一项动作；若证据已经充分，则终止调查并生成回答；若已经无法获得关键证据，则进入部分回答或 insufficient_evidence 状态。

为了防止 Agent 在复杂问题上形成无限循环，调查过程设置了明确的执行预算，包括最大调查步骤数、最大工具调用总数、重复调用限制、文档检索次数以及连续无新增 Evidence 的终止条件。因此，FinTrace 所采用的自主调查是一种具有明确边界和停止条件的有限搜索过程，而不是无限扩展的 ReAct 式推理。

2.3 长周期记忆、动态路由与受控自纠错

长周期金融问答的主要难点并不只是对话内容变长，而是随着轮次增加，历史信息中真正与当前任务相关的部分所占比例不断降低。如果每一轮都将全部历史内容重新输入大语言模型，不仅会显著增加上下文成本，也容易使已失效的实体、时间和旧任务持续干扰当前判断。FinTrace 因此采用分层记忆方式维护 Session 状态，将近期原始消息、结构化上下文、滚动摘要与已验证事实

分别承担不同职责。

近期原始消息主要保留距离当前轮最近的完整用户输入和 Agent 回答，用于解析局部指代、简称和连续追问。当前实现的常规消息窗口上限为 12 条。当达到固定轮次、消息窗口超过设定规模或累计字符数超过阈值时，系统启动 `memory_summarizer`，将即将离开窗口的历史信息与既有摘要进行合并。摘要成功后保留最近 8 条原始消息；如果摘要调用失败，则继续保留最近 12 条并记录警告，不影响已经完成的当前回答。

结构化 `CurrentContext` 保存当前公司、人物、比较对象、时间、指标和任务等信息，用于维持多轮查询中的明确状态。相比仅依赖自然语言历史，结构化状态能够更稳定地处理“那另一家公司呢”“它的评级呢”等省略式表达。本轮出现的新实体和明确任务优先于历史上下文，只有在当前信息不足且历史状态能够唯一解释时，系统才进行语义继承。

`Conversation Summary` 负责压缩较早的对话内容，使系统能够在不持续回填全部历史原文的情况下保留较长期语境。该摘要用于恢复上下文关系，不被直接视为事实证据。

`Verified Findings` 则属于更严格的已验证事实记忆。其内容不是从最终自然语言回答反向提取，而是直接来自 `Evidence Ledger`。写入该区域的信息必须具有有效 `Evidence ID`，同时保留对应公司、主题、来源工具和来源轮次。大语言模型的猜测、失败工具结果以及没有证据编号支持的结论均不得进入 `Verified Findings`。在后续对话中，这些已验证信息可以作为 `Planner` 恢复研究语境和选择核验路径的依据，但如果相关事实需要再次成为当前回答中的核心结论，系统仍要求本轮工具重新取得 `Evidence`，从而避免“记忆中的旧结论”替代当前证据。

面向赛题提出的 0.5M Tokens 长上下文目标，FinTrace 当前采取的技术思路并不是不断扩大单轮 Prompt，而是通过消息窗口、结构化状态、滚动摘要和验证事实进行分层压缩与按需恢复。现阶段系统已经实现上述分层记忆和会话持久化机制，但 50K—500K Tokens 范围的正式冻结压力测试尚未完成，因此当前白皮书仅将其描述为面向超长上下文目标的已实现架构基础，而不直接表述为 0.5M Tokens 技术指标已经达到。后续将通过统一压力测试进一步验证关键事实召回率、任务连续性和回答准确率。

在工具路由方面，FinTrace 同样不采用简单的关键词映射方式，而是根据当前任务、主体状态、时间约束、已有 `Evidence` 和 `Capability Gap` 共同确定下一步动作。当前系统提供财务分析、股权分析、事件时间线、研报观点分析和文档检索五类工具。财务工具负责指标查询、比较及风险扫描；股权工具负责股东快照、变化比较和有限持股路径；事件工具负责事件节点查询及事件聚合；研报观点工具负责机构评级、盈利预测、风险提示与分析师判断；文档检索则主要承担公告、研报及其他金融文本的原文证据补充。

工具之间采用分层协同，而不是互相替代。例如，用户询问“证券机构如何评价某家公司”时，系统优先通过 `research_analysis` 获取带有机构、日期、观点类型和来源的结构化结果；只有当用户进一步追问“为什么得出这一判断”或“原文具体如何描述”时，才调用 `document_search` 获取对应研报 `Chunk`。对于事件问题，系统先通过 `event_timeline` 定位结构化事件，再根据用户对金额、

原因、整改细节等正文信息的需求调用文档检索。该机制减少了大模型直接面对大规模无关文本的需要，也使不同类型证据的语义边界更加明确。

为了控制 Planner 的错误动作，FinTrace 在工具执行前设置了 Action Validator。该模块检查工具名称、Operation、Schema 参数、目标实体、报告期、知识截止日、重复调用及调查预算。当 Planner 输出非法动作时，系统只允许进行有限修复或重新规划，不进入无限反思循环。工具执行后，系统继续区分成功、可重试失败、不可重试失败、DATA_NOT_AVAILABLE、insufficient_data 与 not_applicable 等状态，从而避免将“当前数据没有命中”误写成“现实世界中不存在”。

由此，FinTrace 的自纠错机制表现为一个受控制的工程闭环。系统首先识别动作或工具结果中的异常，再根据错误类型决定是否允许修复或重新规划，修复后的 Action 重新进入合法性检查，超出预算或无法恢复的情况则明确终止。整个过程中产生的原始 Action、校验错误、修复结果、工具返回、证据缺口和终止原因均记录在 Trace 中，为后续工具调用 Precision、自纠错成功率以及失败案例分析提供可直接复用的数据基础。

2.4 Evidence 约束与可追溯回答机制

FinTrace 将 Evidence 作为连接金融工具与最终自然语言回答的核心中间状态。防幻觉并不是通过在 Prompt 中简单要求模型“不要编造”来实现，而是通过对“哪些内容能够进入最终回答”建立明确的程序约束。

每个经过工具结果验证的有效结果都会被转换为具有唯一 evidence_id 的事实单元，并写入 Evidence Ledger。Evidence 中保留来源工具、Operation、目标对象、对应时间、原始数据或文本定位、必要的计算输入和公式、质量标记以及适用限制。对于文档类结果，Evidence 可以进一步追溯至 chunk_id、document_id 和原始材料位置；对于财务、股权、事件及研报观点结果，则能够回到对应结构化数据源和工具执行记录。

Document 与 Chunk 的设计进一步保证了文本证据的稳定性。比赛语料首先被转换为规范化 Document，再按照标题、段落、列表和表格等语义边界形成冻结 Chunk。每个 Chunk 均具有稳定的 ID、内容哈希、语料版本和来源位置。在线检索先按照证券主体、文档类型、报告期、发布日期和知识截止日进行结构化过滤，再融合 FTS5/BM25 词法召回与向量相似度检索。由此，系统不仅能够找到与问题语义接近的文本，还能够将最终引用定位到确定的源文档和文本范围。

Evidence Ledger 中的内容在进入 Final Answer 之前还需要接受 Evidence Review。Reviewer 重点判断当前 Evidence 是否已经覆盖用户问题中的核心子任务，以及不同来源之间是否存在明显冲突。当核心问题已经具备充分且一致的证据时，系统进入回答生成；当部分内容已经得到支持、部分内容仍存在非阻断缺口时，系统允许形成部分回答，并明确说明尚未覆盖的部分；当关键结论缺少证据且剩余调查预算内也无法进一步补足时，则返回证据不足状态。

最终回答同时保存 used_evidence_ids，用于标记真正支撑本轮结论的 Evidence。因此，从最终文本可以沿着 Evidence ID 回溯至工具调用结果，并进一步定位至结构化数据记录、Document 或

Chunk，从而形成完整的证据链。

在最终表达阶段，系统进一步区分客观事实、系统推论、证券机构观点、风险信号和能力限制。客观事实必须能够直接回指 Evidence；系统推论需要说明依据及不确定性；研报观点必须保留机构或分析师归属；财务风险信号只能解释为异常或预警，不能直接升级为财务造假结论；有限持股路径也不能表述为已覆盖全部工商信息的完整控制关系。对于当前没有实时行情、用户账户或其他必要数据支持的问题，系统明确披露能力边界，而不是利用相邻数据或语言常识生成替代性结论。

如果最终回答模型调用失败，系统进入 Structured Error 状态并返回明确错误信息，不使用固定文本模板模拟已经完成的智能分析。结合前述请求解析、Pre-Answerability、Action Validation、Tool Result Validation 和 Evidence Review，FinTrace 最终形成了贯穿完整链路的可信控制体系，使金融智能问答从传统的一次性文本生成过程转变为任务可解析、动作可约束、工具可验证、证据可回溯、错误可修复和能力边界可解释的 Agentic AI 执行过程。




图 1 FinTrace 智能体执行流程

3 核心金融研究能力及其工具化实现

金融研究的本质并非信息的简单堆砌，而是在不确定性中寻找可验证的事实。FinTrace 的系统设计始终围绕一个核心原则展开：将复杂研究任务拆解为可独立验证的专业能力单元，由确定性工具完成事实提取与精确计算，大模型承担研究意图理解和跨工具综合。以下从五个维度系统阐述这一能力体系的构建逻辑与金融分析实践。

3.1 金融数据底座与统一表示

金融研究的首要难题是数据异构。一份上市公司年报包含结构化财务数据、半结构化文本、非结构化描述以及时序关联信息等。传统研究依赖分析师手工翻阅、摘录和比对，不仅效率低下，更关键的是无法保证跨数据源的一致性。本团队通过分层标准化解决这一难题。

FinTrace 将公告与研报等非结构化文本统一构建为 Document，并进一步切分为可追溯的 Chunk；对于财务报表与股东快照则保留结构化字段。不同数据通过统一证券主体、日期语义和 Evidence 协议进入工具层，形成 Raw Data → Normalized Data → Document / Structured Facts → Index → Financial Tools 的完整流水线。Document 保存文档类型、公司标识、标题、发布日期、正文和来源定位；Chunk 保留 document_id、章节语义与字符偏移，使检索结果能够反向定位原始材料。结构化数据则按公司、报告期、观察日期和信息截止日期执行精确查询。

整个数据底座由五类核心数据集构成。多轮问题集仅用于评测多轮理解能力而非事实证据；十大股东快照包含特定日期的前十大股东及持股，但不能代表完整股东名单、实际控制人或完整基金持仓；违规公告索引及正文提供监管与处罚信息，但若无正文则只能回答标题、日期和分类；三张财务报表支持财务指标查询与风险信号识别，但不能直接证明财务造假；研报元数据和摘要属于机构观点，并非客观事实，且当前不含全文细节。另外数据集中关于“最新”一律理解为用户提问时间点之前已披露的最新记录，而非现实世界的实时状况。不同类型的数据、工具与研究任务之间的映射关系如下表所示。

表 3 数据、工具与研究任务映射

数据类型	核心工具	主要研究任务
公告与研报	Document Search	原文检索、监管事项和机构观点查证
公告及事件数据	Event Timeline	事件筛选、聚类、排序与演化重构
财务报表	Financial Analysis	指标查询、跨期比较、跨表勾稽与风险识别
股东快照与关系数据	Ownership Analysis	主要股东查询、持股变化、集中度与有限路径穿透

3.2 文档检索与事件研究

文档检索是上市公司研究中最基础、最频繁的操作，但传统搜索工具存在两个致命缺陷。其一，关键词匹配无法处理语义变体，如搜索“关联交易”可能遗漏表述为“与关联方发生的交易”的段落；其二，向量检索虽能补充语义相似，却可能在精确词项上召回失败。FinTrace 的 document_search 通过混合检索模式解决这一矛盾。

document_search 面向公告和研报执行公司，对文档进行归类汇总和日期过滤，并组合 BM25 确保精确召回与向量检索来补充语义相近表达。BM25 算法基于词频-逆文档频率并改进，对公司

名、财务术语如“货币资金”“存货跌价准备”、监管文件标题和日期等精确词项具有稳定的召回能力。同时设置多关键词检索的功能提高精度。向量检索基于深度语义嵌入模型，系统将 Chunk 和查询语句映射至同一向量空间，计算余弦相似度。当研究者搜索“公司是否通过关联方进行利益输送”时，即使公告原文使用“与关联企业发生的非经营性资金往来”等不同表述，向量检索仍能有效召回。Hybrid 模式通过加权融合两路候选结果，并设置单篇文档重复返回 Chunk 数量上限，避免同一公告的冗长正文淹没其他来源的关键信息。

在金融实践中，事件序列的密度分析——即单位时间内异常事件的发生频率，往往是识别治理风险的有效先行指标。事件研究法是一种通过分析特定事件对股价或个体行为影响的实证研究方法，其核心是计算异常收益率和累积异常收益率来衡量市场反应。其理论基础是有效市场假说，事件研究法以事件发生日为中心，通常定义事件前后若干交易日为时间窗口期，并与事件未发生时的历史数据区间的正常收益率进行比较从而捕捉事件的即时影响和后续影响。event_timeline 是文档检索在时序维度的延伸，用于回答“某家公司一段时间内发生了什么”。工具以事件研究法为基本逻辑，按公司、事件类型和时间范围过滤记录，并对相近事件进行聚类 and 排序，使研究由单篇公告检索扩展为事件序列重构，适用于监管处罚、重大事项变化和持续风险跟踪等任务。其中事件类型业绩预告修正、监管问询、高管变动、行政处罚等。

3.3 财务分析与风险识别

财务分析的本质是从海量财务数据中提取经济含义，而风险识别的关键在于识别数字背后的异常模式，而非孤立地阅读报表。FinTrace 的 financial_analysis 工具将这一专业分析流程固化为可重复执行的操作逻辑，其核心思路不是简单的指标查询，而是构建从“数据读取”到“勾稽校验”再到“信号触发”的完整推理链条。工具首先依托统一指标目录连接资产负债表、利润表和现金流量表三大财务报表，自动完成以下期间口径的严格校验与合并报表和母公司报表的区分处理两项基础性工作。在完成基础数据准备后 financial_analysis 按照专业分析师常用的多维框架展开重点指标分析。针对用户提出的问题分别进行单指标检索、单指标跨期跨公司比较和多指标跨表勾稽。

在盈利能力与收入质量维度，系统不仅计算营业收入、净利润及同比增速，更核心的是执行“收现比”与“净现比”两个经典勾稽校验——前者将主营业务收入与销售商品或提供劳务所收到的现金进行跨表对比，若某企业营收增长 30% 而销售收现仅增长 5%，系统会提示“收入现金保障程度偏低”；后者将净利润与经营活动现金流净额进行跨表对比，若企业连续两年净利润为正且增长，而经营现金流持续为负或急剧萎缩，系统触发“账面利润含金量存疑”的风险信号，这一模式在康美药业、康得新等典型造假案例中均曾出现。在资产质量与营运资本维度，系统将应收账款的增速与营业收入增速进行跨期动态比较，若应收账款周转天数连续三个报告期显著上升而营收增速放缓，标记为“收入确认质量需关注”；将存货增速与营业成本增速进行对比，若存货积压远超成本增长且无明显季节性解释，提示“存货减值风险”。在偿债能力与流动性风险维度，系

统结合流动比率、速动比率、利息保障倍数货币资金占总资产比重和短期有息负债占总负债比重等重点指标，构建压力测试框架，当货币资金与经营现金流之和难以覆盖一年内到期债务时，自动触发流动性预警。所有这些校验规则并非人为随意设定，而是基于监管机构发布的财务舞弊识别指引和审计实务中的关键审计事项总结而来，具有明确的专业依据。

此外 `financial_analysis` 的操作逻辑还有一个关键设计：所有勾稽校验均保留明确的数值边界和计算过程，每个风险信号都附带具体的数值差额、比率变化和所涉及的报表项目，使研究者可以清晰地判断信号强度。例如，系统不会模糊地说“利润与现金流不匹配”，而是精确输出“2023年全年净利润 5.2 亿元，同比增长 18%；经营活动现金流净额 0.8 亿元，同比下降 65%，净现比由上年同期的 0.85 降至 0.15”。同时，系统严格遵守风险信号与事实结论的边界，所有输出均表述为“异常波动”“需进一步查证”“值得关注”等风险提示，绝不越界做出“财务造假已成立”或“确认欺诈”的判定。风险信号也可作为查证触发器，引导 Agent 后续调用 `document_search` 查找审计意见中的关键审计事项、管理层在年报中对异常波动的解释、以及监管机构是否曾就此发出问询函，从而将财务数字分析与文本证据查证有机结合，形成完整的调查闭环。

3.4 股权关系与穿透分析

股权结构是理解上市公司治理格局和控制权归属的关键维度，但股权分析的复杂性远高于查询一个主要股东列表。其复杂性源于多重因素，金字塔式多层持股使控制权与现金流权分离、一致行动协议使名义上的独立股东实际形成联合控制、有限合伙企业的 GP-LP 结构使出资人与控制人身份分离、而代持和通道安排则使名义股东与实际权益人难以对应。`ownership_analysis` 工具的操作逻辑正是在这种复杂性中，基于现有数据的支撑能力，建立了“可验证范围内有限穿透”的分析框架。`ownership_analysis` 的设计遵循两个核心原则：时序可比与证据边界显式化。

工具首先将十大股东快照组织为严格的时序关系数据，其最基本的操作是快照差分比较。当研究者关注某家公司在特定事件前后的股权变动时，`ownership_analysis` 可以精确定位两个观察时点的十大股东名单，自动执行集合运算，输出进入名单的新股东、退出名单的原股东、以及在两个时点均有持股的股东的增减持方向和具体比例变化。这种差分比较并非简单展示差异，而是通过时间维度的对齐，将股东变化与公司重大事件进行关联——例如，若发现某主要股东在公司发布业绩预亏公告前的一个月内减持了 3% 的股份，系统会标注这一时间先后关系作为事件线索，供研究者进一步判断是否存在内幕交易嫌疑。工具还支持反查模式，即查询某一特定主体（如某知名投资机构、某地方国资平台、某自然人）在某一时点出现在了哪些上市公司的主要股东名单中，这对于识别资本系族和关联网络具有直接应用价值。

在穿透分析层面，`ownership_analysis` 遵循严格的有限深度路径搜索逻辑。系统只在数据中能够通过唯一标识（如统一社会信用代码、工商注册号或证监会统一编码）可靠连接的主体之间建立关系边，沿持股链向上追溯或向下穿透，搜索的深度虽然有限，但每一步跳跃都必须绑定可追溯的 Evidence——即该持股关系所依据的具体数据来源，如年度报告中披露的主要股东信息、权

益变动报告书或发行人的上市公告书。这种设计保证了每一条穿透路径都是可验证的，而非基于概率或模型推断。例如，若查询“某省国资运营公司是否通过多层主体控制某上市公司”，系统会先检查国资公司是否直接出现在该上市公司的十大股东中；若未出现，则检查国资公司是否控股某中间投资平台，而该平台又出现在十大股东中；每一层关系都附带相应的股权比例和披露来源。如果某一层缺少数据支撑（如中间主体未在十大股东中披露），系统则在该处停止并返回“证据不足，无法完成穿透”，而不是尝试使用外部工商数据库的模糊匹配来强行补全。

`ownership_analysis` 操作逻辑中最为关键的设计是其数据边界的显式管理机制。工具明确知晓十大股东快照的固有局限，这些数据仅覆盖达到披露门槛的主要股东，无法反映完整的股权全貌。因此，系统在使用时会显式保留数据边界，自动标注其分析结论的适用范围。关于主要股东的进入退出和增持减持，属于“可回答”范围；关于完整实际控制人的认定、一致行动关系的确认、非主要股东的持股情况、以及未上市中间层级的穿透，均属于“部分可回答”或“不可回答”范围，系统会在结论中明确声明这些限制，只对现有数据能够支持的路径做出陈述。这种保守但有据可循的策略，使股权分析的结论始终保持专业审慎，避免系统输出看似确定但实际无据的误导性结论，这在合规敏感的投资研究和风险管理场景中具有不可替代的价值。

3.5 多工具协同研究

FinTrace 在工具选择上遵循奥卡姆剃刀原则——在选择工具时选择最少最简洁最必要的方案，如无必要，勿增实体。若问题只需查询财务数字，就不额外调用文档搜索或事件工具；若问题只需检索公告原文，就不叠加股权分析。其工作流程为四步迭代：

Plan Next Action → Retrieve / Calculate / Trace → Evidence Review → Next Action or Conclusion

每一步动作由当前问题与已有证据共同决定，直到关键方面被覆盖或系统确认剩余缺口无法可靠补足。对于需要多工具的综合问题则需协同考虑。因为 FinTrace 的核心能力不是四个孤立接口，而是根据 Evidence Gap 逐步组合工具。例如综合风险研究可先由 `financial_analysis` 发现异常信号，再通过 `document_search` 查证审计意见与监管问询，使用 `event_timeline` 重构事件演化，必要时调用 `ownership_analysis` 检查主要股东在异常期间的持股变化。每一次工具调用产生的 Evidence 均累积为可追溯的证据链。这种模式将传统 RAG 的“检索文本—生成答案”扩展为证据驱动的连续调查：能答的问题确保有据可依、边界清晰；不能答或只能部分回答的问题，系统需诚实标记数据边界并拒答，而非强行拼凑结论。在金融研究与投资决策中，可验证的证据链与诚实的边界声明，远比流畅但不精确的文本生成更具实际价值。

4 可信回答与全链路可追溯机制

金融领域的智能 Agent 不仅需要具备信息检索、数据分析和自然语言生成能力，还需要保证回答所依据的信息真实可查、符合研究时点，并能够解释结论形成的过程。对于财务数据、股权关系、重大事件和研究观点等金融信息而言，数据来源、有效时间以及证据与结论之间的对应关系都会直接影响分析结果的可靠性。因此，FinTrace 将可信回答能力嵌入 Agent 的完整执行流程，而不是将其作为最终答案生成阶段的附加功能。

FinTrace 以 Evidence 为核心组织金融研究过程中的事实信息，并通过 Evidence Ledger 对不同工具产生的证据进行统一管理；通过 `as_of_date` 和 `knowledge_cutoff` 对研究时点和信息可得范围进行约束；通过 Evidence Review 判断当前证据是否已经足以支撑用户请求，并利用 Evidence-to-Claim 建立证据与最终结论之间的对应关系。在此基础上，系统进一步记录从用户请求、任务解析、Agent 决策、工具调用、证据形成到最终回答的完整 Trace，使每一次研究任务都能够形成可检查、可复核的执行记录。

因此，FinTrace 所强调的可信并不是简单地为回答增加引用，而是将“信息从哪里来、在什么时候可以使用、能够支撑什么结论以及最终答案如何形成”统一纳入系统运行机制之中。其核心原则可以概括为：大模型负责组织调查过程，确定性工具负责获取和计算事实，证据负责约束最终结论，Trace 负责记录全过程。

4.1 统一证据对象与 Evidence Ledger

FinTrace 将 Evidence 定义为 Agent 执行过程中的结构化证据对象，而不是传统检索增强系统中仅供模型阅读的文本片段。在一次金融研究任务中，财务指标、股东关系、公司事件以及文档内容可能来自不同的数据源和不同的工具，如果直接将这些结果交由大语言模型处理，后续很难准确判断某一结论究竟由哪一项信息支撑。为解决这一问题，FinTrace 对不同工具产生的信息进行统一封装，并通过唯一的 `evidence_id` 对每条证据进行标识。

Evidence 对象包含证据类型、来源、结构化事实以及支持强度等信息。不同来源的信息经过工具处理后，被转换为统一的证据形式，并进入 Evidence Ledger。系统目前能够处理文档、财务事实、持股关系和事件等类型的 Evidence，同时保留相应的来源定位信息，使结构化数据和非结构化文档都能够进入统一的证据体系。

Evidence Ledger 则承担一次研究任务中的证据汇总和状态管理功能。对于简单查询，Ledger 可以保存当前问题直接需要的事实；对于需要多轮调查的复杂问题，不同工具在不同阶段产生的 Evidence 可以持续累积，使 Agent 能够根据已有证据判断当前已经掌握的信息以及仍然存在的缺口。Evidence 与产生它的工具动作之间通过 `used_by` 等关系进行关联，从而保证证据不仅能够被使用，还能够被追踪。

每条 Evidence 具有唯一 `evidence_id`，保存证据类型、来源、结构化事实、支持强度和使用关系。其核心字段如表 4 所示。

工具执行后，Evidence 按 evidence_id 合并进入 Evidence Ledger。原始来源、工具结果和自然语言 Claim 因而形成：

Source → Tool Result → Evidence → Evidence Ledger → Claim

在这一过程中，Evidence 成为了连接数据和回答的中间层。最终结论不再直接建立在模型对原始检索结果的自由解释之上，而是建立在经过工具处理并被系统记录的结构化证据之上。

表 4 Evidence 核心字段

字段	含义
evidence_id	唯一证据标识，用于回答引用、日志与评测对齐
evidence_type	文档、财务事实、持股关系、事件等证据类型
source	Document、公司、页码/行号或数据路径等来源定位
fact	工具提取、查询或确定性计算得到的结构化事实
support_level	direct、derived 或 weak 支持强度
used_by	记录产生或使用该证据的工具动作

4.2 金融信息的时间一致性约束

金融数据具有明显的时间属性。同一家公司在不同时间点的财务状态、股东结构和重大事件可能完全不同，而研究人员在历史时点进行分析时能够获得的信息，也不等于今天数据库中能够查询到的全部信息。因此，金融智能 Agent 如果缺少明确的时间边界，就可能在历史分析中使用研究时点之后才公开的数据，从而产生前视偏差。

FinTrace 通过 as_of_date 和 knowledge_cutoff 两个时间维度解决这一问题。as_of_date 用于描述业务观察时点，即需要研究对象在什么时候的状态；knowledge_cutoff 则用于描述知识可得截止时间，即在本次研究中允许系统使用到什么时候公开的信息。其核心字段如表 5 所示。

两者并不是相同的概念。前者回答的是“研究对象在什么时候是什么状态”，后者回答的是“在这个研究环境中系统当时能够知道什么”。系统在形成有效 Evidence 时需要同时满足相应的时间约束，因此数据库中的最新数据并不天然意味着可以用于当前任务。对于历史研究任务，只有符合知识截止时间的信息才能进入当前研究证据范围。

通过这一机制，FinTrace 将时间一致性从回答层面的文字说明转变为 Agent 执行过程中的约束条件。对于需要进行历史财务分析、股权关系分析或事件研究的问题，系统能够在既定的信息边界内组织调查和形成证据，从而降低未来信息进入历史研究过程的风险。

表 5 FinTrace 双时间约束

时间参数	定义	主要作用
as_of_date	业务观察时点	确定公司、股权、事件等研究对象在特定时点的状态
knowledge_cutoff	信息可得截止时点	限制系统在研究过程中可以使用的公开信息范围

4.3 Evidence Review 与 Evidence-to-Claim

在金融研究中，获得相关资料并不意味着已经具备形成结论的充分条件。一个复杂问题可能同时包含财务表现、股权结构和重大事件等多个方面，而一次工具调用通常只能覆盖其中的一部分。因此，FinTrace 在工具执行之后进一步进行 Evidence Review，对当前证据是否足以支撑用户请求进行判断。

系统通过 Post-Answerability 对当前 Evidence 进行审查，并记录已经覆盖的研究方面以及仍然存在的 Evidence Gap。根据当前证据状态，系统将证据状态划分为：

sufficient：当前证据足以覆盖所需研究方面，可生成完整回答；

partial：部分方面已有证据，其余无法继续可靠补足，生成部分回答并说明限制；

insufficient：没有获得能够支持回答的有效证据，返回证据不足。

当现有证据已经能够覆盖问题要求时，系统进入最终回答阶段；当只有部分内容获得充分证据时，则保留已经确认的部分并明确回答边界；当证据不足但现有工具能力仍然能够解决相应缺口时，系统不会立即生成答案，而是进入 Investigation Loop，根据当前 Evidence Gap 规划下一项调查动作，并继续调用相应工具补充证据。

这一机制使复杂金融任务从一次性的“检索—生成”模式转变为持续的证据调查过程。Agent 每完成一轮工具调用，都会将新的结果转化为 Evidence 并重新进行审查。如果当前证据仍无法覆盖用户请求，系统继续根据 Evidence Gap 规划后续动作；只有当证据已经满足回答条件，或者剩余问题无法通过现有能力进一步解决时，才结束 Investigation Loop。由此，系统不会因为已经获得少量相关信息就过早生成完整结论，而是以证据覆盖程度作为结束调查的重要依据。

更重要的是，FinTrace 对最终自然语言生成设置了明确的证据边界。最终回答只能使用已经产生的 Tool Result、Evidence 以及系统记录的限制条件进行组织和归纳，逻辑上要求：

$$\text{Claim} \subseteq \text{Supported}(\text{Evidence Ledger}).$$

也就是说，最终回答中的事实性 Claim 必须能够在当前 Evidence Ledger 中找到相应的支持。模型可以对多条已有证据进行归纳、比较和综合，也可以将多个 Evidence 组织成更高层次的分析性表述，但不能利用自身参数知识补充 Evidence 中不存在的具体事实。对于金额、比例、时间、持

股关系以及事件细节等金融信息，除非已经存在相应证据，否则模型不能自行补充或推断具体数值。

这一约束尤其适用于金融异常和风险判断。系统允许根据已有财务指标或相关事实描述“存在风险信号”或“值得进一步关注的异常”，但不能仅凭单项指标异常直接生成更强的事实性结论。只有在 Evidence Ledger 中存在额外证据，并且这些证据能够共同支持更强结论时，模型才可以进一步提升结论强度。这样可以避免模型将“指标异常”直接扩大为已经确认的违规、造假或其他未经验证的事件。

例如，当工具返回某项财务指标出现明显异常时，系统可以基于该 Evidence 表述为“该指标表现出异常特征，可能构成一定风险信号”；但如果当前 Evidence Ledger 中不存在进一步的审计结论、公告信息或其他独立证据，就不能直接将其表述为已经确认的财务造假。类似地，如果 Evidence 只记录某一主体持有公司一定比例股份，模型可以据此描述对应的持股事实，但不能在没有控制权、协议安排或其他证据的情况下自行扩展为“实际控制”关系。

因此，Evidence Review 和 Evidence-to-Claim 实际上形成了从“是否继续调查”到“最终能够说什么”的两层约束。前者控制调查过程的终止条件，后者控制自然语言生成的事实边界，使 Agent 在面对复杂金融问题时既能够主动补充证据，又能够在证据不足时保持克制。

这一机制最终使 FinTrace 的回答生成从传统的“模型知道什么就回答什么”转变为“Evidence Ledger 中有什么，系统才允许回答到什么程度”。模型的作用由直接提供事实转变为在既有证据范围内进行组织、归纳和表达，从而在保留大语言模型分析能力的同时，显著降低无依据事实补充和结论过度推断的风险。

4.4 结构化回答状态与拒答

可信回答并不意味着系统必须对所有问题给出完整答案。在实际金融研究中，用户可能没有提供必要的公司主体、时间范围或比较对象，也可能存在数据源缺失、证据不足或者工具执行失败等情况。如果系统在这些情况下仍然要求模型输出完整结论，就容易将推测包装成事实。

FinTrace 因此将最终回答状态进行结构化处理。系统根据实际执行结果区分完整回答、部分回答、需要澄清、不支持、证据不足以及执行失败等情况，并通过不同的状态值反映当前任务的真实完成程度。

这种设计使“拒答”成为系统可信机制的一部分，而不是异常情况。当证据不足以支撑某项结论时，系统不会为了保持回答完整性而自行补充未知事实；当用户输入不足时，也不会擅自猜测主体或时间条件。对于已经获得部分证据的问题，则可以保留能够确认的内容，并明确尚未得到充分支持的部分。

对于金融智能 Agent 而言，这种能力尤其重要。金融研究更加重视事实边界和证据质量，一个明确说明“当前证据不足”的结果，其可信程度往往高于一个信息完整但来源无法验证的答案。因此，FinTrace 将“知道什么”和“不知道什么”都纳入结构化回答状态，使系统能够对自身能力

表 6 主要回答状态及含义

状态	含义
answered	已获得充分证据并完成回答
partially_answered	仅部分问题获得充分证据
clarification_required	用户输入缺少必要主体、日期或比较条件
unsupported	当前系统不存在所需工具、数据源或权限
insufficient_evidence	能力存在，但本次实际证据不足
failed	工具、模型、网络或程序执行失败

和当前证据边界进行明确表达。

4.5 执行 Trace 与全过程审计

如果说 Evidence 解决的是“回答依据什么”，那么 Trace 解决的就是“回答是如何产生的”。FinTrace 将一次 Agent 运行视为完整的研究过程，对从用户请求进入系统到最终回答生成的关键执行状态进行统一记录，使一次任务不再只留下最终文本，而是形成可以回溯和分析的完整运行轨迹。

在每次运行过程中，系统持续记录 Parsed Request、Pre-Answerability、Routing Mode、Planner Action、工具执行结果、Evidence ID、Evidence Gap、动作修复信息、模型调用信息、Answer Status、Termination Reason 以及错误和延迟等运行元数据。这些信息覆盖了请求理解、任务判断、Agent 路由、工具执行、证据形成、调查修复和最终回答等关键阶段，使一次金融研究任务能够被还原为结构化的执行记录。完整审计链可以表示为：

Query → Parsed Request → Action → Tool Result → Evidence → Review → Final Answer

这一链路同时对应了 FinTrace 从问题理解到答案生成的核心执行过程。用户提出的问题首先经过结构化解析，系统判断当前任务是否具备直接回答的条件，并根据任务类型选择相应的 Routing Mode；对于需要进一步调查的问题，Planner 生成下一项 Action 并调用相应工具。工具产生的结果经过标准化后进入 Evidence Ledger，并在 Evidence Review 中判断是否已经满足回答要求。如果仍然存在 Evidence Gap，系统可以继续规划后续动作，直到证据达到回答条件或任务进入相应的终止状态。

Trace 的价值不仅在于保存执行记录，更在于能够对问题进行分层定位。当最终结果出现异常时，系统可以沿着 Trace 检查问题究竟发生在请求解析、Direct Gate/Planner 路由、工具及其数据、Evidence Gap 处理，还是最终回答生成阶段，而不必将所有异常笼统归因于“大模型幻觉”。这种定位方式使 Agent 的错误分析从单纯的结果评价进一步转向执行链路级别的诊断。

例如，当最终回答中的金融数据出现错误时，可以首先检查对应的 Evidence ID 和 Tool Result，

判断错误是否已经存在于工具返回的数据中；如果工具结果正确，则可以进一步检查 Evidence 是否被正确记录以及 Evidence-to-Claim 是否建立了正确关联；如果证据本身没有问题，则可以继续检查最终回答是否超出了 Evidence Ledger 所支持的范围。类似地，如果系统没有完成任务，也可以通过 Termination Reason 和 Evidence Gap 判断是因为缺少必要输入、当前工具能力无法覆盖，还是调查过程中的执行异常。

此外，同一套 Trace 数据还可以直接服务于系统评测。由于每一次工具调用、Evidence 形成、动作修复和最终回答状态均被结构化记录，因此 Trace 不仅能够回答“这次任务为什么得到这个结果”，还能够进一步统计 Agent 在大量任务上的运行表现。例如，可以基于工具调用记录评估工具调用 Precision，通过动作修复和任务最终状态分析自纠错成功率，通过 Evidence 与用户任务需求之间的覆盖关系计算证据覆盖率。这样，Trace 同时成为系统运行日志、问题诊断机制和评测数据基础。

由此，FinTrace 将传统 Agent 中相对分散的日志、工具调用记录和模型运行信息统一纳入同一 Trace 体系，使每一次研究任务都能够形成从问题输入到最终回答的完整审计链。最终实现的不仅是“答案可追溯”，更是“答案形成过程可解释、执行问题可定位、系统能力可量化评估”。

5 实验设计与结果

金融智能体的可靠性需要从回答质量、工具行为、证据支撑和运行效率等多个维度综合评价。FinTrace 需要在多轮对话中识别公司、时间和任务，选择财务、文档、股权或事件工具，并将结构化结果组织为有证据约束的金融研判。任何一个环节发生错误，都可能引发主体错配、期间错配、数值错误、前视偏差或无证据结论。

本章采用“端到端智能体、确定性工具、专业报告”三层评测框架，将竞赛要求转化为**九项可复现指标**，并通过统一运行轨迹关联请求解析、工具调用、证据审查和答案生成。各类实验均按照“评价目的—指标来源与计算方法—实验结果—结果分析”的顺序展开，使指标选择、测量过程和业务结论保持对应。

5.1 实验设置

5.1.1 评测任务与数据集

多轮问答评测集由 35 个会话和 1,410 个轮次构成，每个会话包含 12 至 85 轮。问题覆盖事实查询、跨期比较、财务风险分析、股东关系、股权穿透、事件脉络、公告检索、研报观点及超出数据边界的问题。根据给定数据和工具能力，样本划分为可回答、不可回答和需要澄清三类。

所有会话均按照原始轮次顺序连续回放，依赖上下文的问题随完整会话一并评价。长上下文压力集在原始会话基础上扩展，使累计对话历史和可访问材料达到 0.5M Tokens，并设置早期主体与指代、早期数值、跨轮期间约束和无关话题切换四类探针。实验同时记录数据集累计 Token、各

次大模型实际输入 Token 和记忆模块召回内容，以区分模型窗口、记忆压缩和检索策略的贡献。

专项工具在结构化结果层接受独立评价，具体做法是比较工具输出与独立构建的参考标注或复核结论。不同任务的样本单位和参考内容如下。

表 7 评测任务与参考标注

评测任务	样本单位	核心参考标注
多轮问答	轮次 / 会话	可回答性、核心事实、必要证据
工具路由	逻辑工具调用	可接受工具操作、必要性、关键参数、无需调用工具场景
错误处置与自纠错	实际运行轮次	错误类型、后续动作、最终状态和处置结论
股权穿透	自然语言查询案例	起止主体、观察日、逐跳节点、方向和比例
事件脉络	公司-时间窗案例	核心事件节点、类型、阶段、事件簇和来源
财务风险	公司-报告期-风险类型	正负标签、风险期间、指标证据和判定理由
报告盲评	财务排雷报告	专家维度评分、否决性错误和优秀标签

5.1.2 模型与运行配置

智能体的主回答模型与规划模型分别配置，以支持独立替换和对照实验。本次实验统一使用 Qwen 模型，所有结构化推理模块的温度设为 0，以降低随机性。知识截止日由 workflow 统一注入，并在规划和工具执行阶段保持不变。

表 8 模型与运行配置

配置项	实验配置
主回答模型	qwen3.7-plus
规划模型	qwen3.7-plus
API 协议	DashScope OpenAI-compatible API
结构化推理温度	0.0
Python 版本	3.12.13
知识截止日	2026-05-28
问题集	35 个会话，1,410 个轮次
实验批次	EVAL-20260825T204302Z-FA59F317-2CB3

每次正式运行设置唯一实验批次编号，并冻结源代码版本、依赖版本、模型、提示词版本、问

题集哈希、数据清单、风险规则、实体映射、运行硬件和随机种子。配置发生变化时创建新的实验批次，以保证同一批次内结果可比。

5.1.3 参考标注构建与质量控制

问题主表保存问题、会话、轮次、主体、日期、可接受工具和必要文本片段。专项参考结果与问题主表分离，并通过案例编号关联。文本片段承担证据定位功能，原子事实承担答案内容判定功能；两者分别记录。参考结果依据冻结原始数据制作，与被评智能体及工具的输出保持独立，并记录生成方式和版本。

正式参考标注采用双人独立标注和第三人仲裁。全量标注前先开展试标，统一实体、期间、单位、事件粒度和风险语义。评测仅纳入完成仲裁的标注。样本排除范围预先限定为重复记录、原始数据损坏或参考结论无法仲裁，并完整保留排除原因。

回答准确率的完整实验设计采用金融标注者和冻结版本大模型评估器双重评价。当前全量结果由冻结版本大模型评估器逐轮审查，并经项目负责人确认后作为代理人工复核结果写入评测表；原始模型标签、映射记录和修改前文件均单独保留。该结果可用于现阶段回答质量统计，但**不等于独立金融专家复核**，后续专家抽查时应优先覆盖错误案例、复杂财务调查和上下文切换案例。

5.2 长上下文问答、工具调用与纠错

5.2.1 回答质量与工具路由评价方法

长上下文实验首先评价系统能否在多轮交互中形成正确的最终回答。回答准确率用于衡量一轮回答是否整体可用，直接对应竞赛提出的“回答准确率”要求。该指标以轮次为单位，依据统一审核标准检查最终回答。对于可回答问题，评价核心内容以及主体、期间、口径、数值和方向；对于不可回答问题，评价数据或能力边界说明和结论审慎性；对于需要澄清的问题，评价已给出的部分结果、缺失参数及其影响是否表达清楚。

主体或期间错配、核心数值或方向错误、使用截止日后信息、错误拒答、虚构证据，以及将风险信号表述为造假事实，均归为实质错误。关键事实召回率（Recall）统计完成任务所必需的原子事实，命中要求主体、期间、指标口径和数值或方向全部正确。

仅使用回答准确率会掩盖“答案整体可接受但遗漏重要事实”的情况，因此同时采用关键事实召回率。该指标直接对应竞赛的关键事实召回要求，其分母来自每道问题经复核确认的必要原子事实集合，分子来自回答中得到正确表达且能够由证据支持的必要事实。所有轮次的事实命中数统一汇总后计算总体召回率，非必要背景信息不进入分母，避免答案篇幅影响结果。

据此，回答准确率与关键事实召回率分别定义为：

$$A_{\text{ans}} = \frac{N_{\text{correct}}}{N_{\text{turn}}}, \quad R_{\text{fact}} = \frac{N_{\text{hit}}}{N_{\text{reference}}}.$$

其中， N_{correct} 表示被判定为正确的回答轮次， N_{turn} 表示纳入评测的轮次总数； N_{hit} 表示回答正确覆盖的必要事实数量， $N_{\text{reference}}$ 表示人工参考标注中的必要事实总数。 A_{ans} 反映回答的整体可用性， R_{fact} 反映必要信息的覆盖程度，两者从整体判断和事实完整性两个角度评价长上下文问答质量。

工具调用评价使用必要调用正确率和轮次级路由正确率。评测以运行轨迹中的逻辑工具调用为单位，同一调用标识内的物理重试只计算一次。对于经复核确认为回答问题所必需的调用，只有工具、操作和主体、时间、指标、事件类型与知识截止日等关键参数全部正确，才计为正确的必要调用。额外调用不进入该指标的分母。

设必要调用总数为 N_{needed} ，其中工具、操作和关键参数均正确的调用数为 $N_{\text{needed_correct}}$ ，则必要调用正确率为：

$$A_{\text{needed}} = \frac{N_{\text{needed_correct}}}{N_{\text{needed}}}.$$

轮次级路由正确率以完整对话轮次为单位。一轮中所有必要调用均正确且没有遗漏必要工具时，该轮计为路由正确。设路由正确轮次数为 $N_{\text{route_correct}}$ ，总轮次数为 N_{turn} ，则：

$$A_{\text{route}} = \frac{N_{\text{route_correct}}}{N_{\text{turn}}}.$$

5.2.2 错误处置与可靠性评价方法

错误处置与自纠错直接使用全量评测过程中真实产生的运行轨迹，不额外注入故障。系统根据结构化运行日志自动识别工具执行失败、动作或参数校验失败、大模型结构化输出错误、网络异常和工作流异常。正确空结果、能力边界内的拒答和有证据依据的数据不足不会产生错误记录，因而不进入该指标。工具路由或回答内容是否正确分别由必要调用正确率、轮次级路由正确率和回答准确率评价，避免在错误处置指标中重复计算。

运行错误率用于观察系统在真实任务中的稳定性，定义为：

$$R_{\text{error}} = \frac{N_{\text{error}}}{N_{\text{all}}}.$$

其中， N_{all} 为全部有效运行轮次， N_{error} 为运行轨迹中至少出现一次可检测错误的轮次。一个轮次内出现多项错误时仍只计一个错误轮次，分类统计允许同一轮同时属于多个错误类型，因此分类数量之和可能大于错误轮次总数。该指标越低，说明系统越少进入异常处理路径。

对于已经发生错误的轮次，系统继续检查最终一次 Agent 运行是否在同一运行内部处理了该轮涉及的全部错误类型，并以非失败状态安全结束。参数修复、重新规划、有界重试后完成任务，以及无法继续时停止生成无证据结论，均属于正确处置；仅由评测脚本在之后重新执行成功的轮次不计为 Agent 自动纠错成功。错误处置成功率定义为：

$$S_{\text{handling}} = \frac{N_{\text{handled}}}{N_{\text{error}}}.$$

其中， N_{handled} 为全部可检测错误类型均在最终一次 Agent 运行内得到处理的错误轮次。本文以 S_{handling} 作为自纠错成功率的统计结果。回答内容是否正确不由该指标重复判断，而由回答准确率单独反映。

为同时体现低错误率和错误发生后的处理能力，实验还报告**总体可靠运行率**：

$$R_{\text{reliable}} = \frac{N_{\text{normal}} + N_{\text{handled}}}{N_{\text{all}}}.$$

N_{normal} 表示未出现运行错误且正常结束的轮次。若整个评测批次未发生运行错误，则 R_{error} 记为 0， R_{reliable} 记为 1；由于此时不存在需要处置的错误， S_{handling} 不再计算。

5.2.3 长上下文、路由与纠错实验结果

依据上述口径，长上下文实验按 Token 档位报告性能变化，0.5M 档用于核对竞赛要求，其他档位用于观察上下文增长是否引起持续性能衰减。表中同时记录端到端 P_{95} 延迟，以呈现不同上下文规模下的响应时间变化；回答准确率和关键事实召回率仍分别依据回答标签与必要事实命中情况计算。

延迟统一以秒为单位。端到端延迟从用户请求进入系统开始，到完整回答返回为止。 P_{50} 延迟是全部样本按耗时排序后的中位数，表示一半请求能够在该时间内完成； P_{95} 延迟是第 95 百分位数，表示 95% 的请求能够在该时间内完成，可用于观察少量慢请求对交互稳定性的影响；最大延迟则记录本次实验中耗时最长的单次请求。

表 9 不同上下文规模下的问答结果

Token 档位	会话数	轮次数	回答准确率	关键事实召回率	端到端 P_{95} 延迟
10K	35	1,111	96.04%	92.37%	42.60 秒
50K	32	249	91.97%	96.64%	225.27 秒
100K	17	48	89.58%	92.98%	489.66 秒
250K	2	2	100.00%	100.00%	646.19 秒
500K	0	0	/	/	/

本表按照每轮工作流内全部大模型调用的输入与输出 Token 总量分档，各档依次表示不超过 10K、10K 至 50K、50K 至 100K、100K 至 250K 和 250K 至 500K。同一会话中的不同轮次可能落入不同档位，因此各档会话数不进行加总。本批次单轮最高 Token 总量为 116,283，未出现 250K 至 500K 样本，500K 档的“0”表示实际运行未形成该规模的模型输入，而非该档回答准确率为 0。

未形成 0.5M Tokens 输入与系统的上下文治理方式有关。FinTrace 不将全部历史消息、公告、研报和工具结果持续拼接到提示词中，而是先对原始文档进行结构化清洗和自然段切分，在线阶段只检索与当前主体和任务相关的少量 Chunk；多轮对话则保留近期消息，并将较早内容压缩为会话摘要和带证据标识的已验证事实。结构化财务、股权和事件结果也以受限证据集合传入模型，文档 Chunk 设置独立数量上限，避免长篇文本挤占关键数值和关系证据。该机制减少了无关历史信息、重复原文和低相关检索结果造成的上下文膨胀，使大部分边界判断在调用模型前完成，也降低了长上下文中的注意力稀释、早期事实遗失、推理延迟和调用成本。因此，现有评测更接近经过检索、摘要和记忆压缩后的实际 Agent 负载，而不是人为累积全部原始内容得到的窗口上限测试。需要说明的是，这一结果证明了系统能够主动控制上下文规模，但不能替代 0.5M Tokens 专项压力实验；若按照竞赛口径验证极限输入条件，仍需另行构造保留关键事实的超长会话进行测试。

全量 1,410 轮回答中，1,341 轮通过审核，回答准确率为 95.11%；248 轮具备可核验的必要事实，共标注 1,160 项，正确命中 1,103 项，关键事实召回率为 95.09%。10K、50K 和 100K 档的回答准确率分别为 96.04%、91.97% 和 89.58%，关键事实召回率分别为 92.37%、96.64% 和 92.98%，未表现出随 Token 用量增加而同步下降的单调趋势。250K 档只有 2 轮，虽然两项指标均为 100%，样本量不足以支持稳定性结论；500K 档没有实际样本，因此仍需独立压力实验。现有错误更集中在时间口径错配、部分回答遗漏、模糊问题的上下文继承，以及证据不足时的回答边界处理。

分领域结果沿用总体轮次级路由正确率的统计口径，每个领域均以 1,410 个对话轮次为分母。若一轮在该领域中出现必要调用错误或遗漏，则该领域在本轮记为路由错误；其余轮次记为正确。同一轮可能同时影响多个领域，因此各领域错误轮次数不直接加总。

表 10 分领域工具路由结果

工具领域	评测轮次数	路由正确轮次数	路由错误轮次数	轮次级路由正确率
财务工具	1,410	1,358	52	96.31%
股权工具	1,410	1,403	7	99.50%
事件工具	1,410	1,381	29	97.94%
文档与研报工具	1,410	1,357	53	96.24%

工具调用实验共记录 570 次逻辑调用。经大模型辅助复核，286 次调用被确认为回答问题所必需，其中 242 次的工具、操作和关键参数均正确，必要调用正确率为 84.62%。在 1,410 个对话轮次中，1,293 轮满足所有必要调用正确且没有遗漏必要工具，轮次级路由正确率为 91.70%。分领域结果用于定位不同工具领域对总体路由错误的贡献。两项指标均不将额外调用计入错误范围。

错误处置结果依据同一批次的运行轨迹统计，并按错误产生环节展开。只有该轮所有错误均

得到妥善处理，才计入正确处置轮次。

表 11 错误处置结果

错误类型	错误轮次数	正确处置轮次数	错误处置成功率
工具执行错误	0	0	/
动作或参数校验错误	56	56	100.00%
大模型输出错误	158	145	91.77%
网络与基础设施错误	8	4	50.00%
总体	214	198	92.52%

全量评测共执行 1,410 轮，其中 214 轮出现轨迹可检测错误，运行错误率为 15.18%；198 个错误轮次在最终一次 Agent 运行内处理了全部错误类型，错误处置成功率为 92.52%，总体可靠运行率为 98.87%。分类统计中，大模型输出错误最为常见，动作或参数校验错误均在运行内完成修复；网络与基础设施错误的自动处置率相对较低，说明外部接口连续失败仍是影响系统稳定性的主要因素。15 轮仅在后续重新执行后恢复，另有 1 轮只处理了部分错误类型，均未计入 Agent 自动纠错成功。

5.2.4 运行效率与资源消耗

为说明回答质量与实际运行代价之间的关系，端到端计时覆盖请求解析、规划、工具调用、证据审查和答案生成。平均 Token 是每轮主模型与规划模型输入、输出 Token 之和的算术平均值，平均成本则根据各模型的实际 Token 用量和调用价格折算。长上下文问答与工具调用的失败分别归入上下文继承、实体与时间解析、工具路由、参数生成、证据审查、答案生成和基础设施，以便将延迟或成本异常与具体工作流程环节对应。

表 12 不同运行场景的效率与资源消耗

场景	样本数	P_{50} 延迟	P_{95} 延迟	最大延迟	平均 Token
确定性直连	163	67.89 秒	160.15 秒	252.77 秒	9,371.96
有界调查	54	155.68 秒	357.23 秒	553.53 秒	36,883.80
多工具调查	115	178.96 秒	435.55 秒	646.46 秒	40,042.33
证据不足或拒答	1,078	0.03 秒	51.57 秒	306.19 秒	2,654.93

确定性直连、有界调查和多工具调查的 P_{95} 延迟分别为 160.15 秒、357.23 秒和 435.55 秒。多工具调查需要经历规划、证据复核和多次工具执行，耗时高于确定性直连；其中，本地 SQLite 查

询和图搜索较快，主要等待时间来自规划模型、最终回答模型以及需要在线生成查询向量的文档检索。证据不足或拒答场景共 1,078 轮，合计调用工具 38 次，平均每轮 0.04 次，多数请求在工具执行前即完成能力边界判断。 workflow 设置了工具预算、重复动作校验和终止条件，可以限制无效循环；整体效率更容易受到外部模型接口网络延迟和响应稳定性的影响。模型调用成本将在按照实际计费单价折算后补充。

本批次共调用大模型 1,725 次，输入和输出 Token 分别为 8,096,426 和 2,889,814。总计 10,986,240 Tokens。该统计包含请求解析、规划、动作修复、证据审查、记忆摘要和最终回答等结构化推理环节。

5.3 股权穿透与事件脉络

5.3.1 股权穿透完整严格准确率

股权穿透的价值在于还原完整、可验证的控制或持股链条，任意一跳的主体、方向或比例错误都可能改变最终结论。因此，本文采用案例级完整严格准确率，而不以单个节点的局部正确代替整条路径的正确。评测范围从工具接收已校验的起点、终点和观察日开始，覆盖实体桥接、图查询、比例计算和结构化结果组装。参考路径由评测程序直接读取冻结股东快照和经确认的主体桥接关系，通过独立 SQL 和深度优先搜索重建，不调用被测路径搜索函数；随后由固定版本大模型复核主体语义和来源支持。一个案例只有在观察日、路径方向、每一跳节点、每一跳比例、累计比例和必要路径全部正确，且不存在无证据额外路径时才通过。

设有效穿透案例总数为 N_{path} ，其中满足全部严格条件的案例数为 N_{strict} ，则股权穿透完整严格准确率为：

$$A_{\text{ownership}} = \frac{N_{\text{strict}}}{N_{\text{path}}}.$$

N_{path} 仅包含路径深度大于 3 且能够从冻结股东快照独立重建完整参考路径的案例。对于一条包含 L 跳的持股路径，其累计持股比例按每一跳比例 r_l 连乘计算：

$$r_{\text{path}} = \prod_{l=1}^L r_l.$$

路径中的节点、方向或任一 r_l 错误，都会使该案例无法计入 N_{strict} ；这与股权穿透结论必须逐跳成立的业务要求一致。

5.3.2 事件节点与事件簇质量

事件脉络实验复用专项性能实验中的 30 家公司及其冻结事件索引，不新增公司或合成事件。外部评审模型在不使用互联网和模型记忆的条件下，依据事件标题、摘要、公告文号、主体、阶

段和日期，从 708 条既有事件中独立识别关键节点并划分参考事件簇。系统聚类结果不作为参考划分依据。该实验评价现有事件索引中的关键节点保留和脉络组织质量，不用于推断系统针对全部原始公告的事件抽取召回率。

设外部评审确认的关键节点总数为 $N_{\text{event_reference}}$ 。其中，被系统事件脉络保留的节点数为 $N_{\text{event_hit}}$ ，则事件节点召回率定义为：

$$R_{\text{event}} = \frac{N_{\text{event_hit}}}{N_{\text{event_reference}}}.$$

该指标衡量关键事件在事件查询和聚类组织过程中是否被遗漏。由于参考节点从既有事件索引中选择，结果只说明索引内节点的保留情况，不能替代基于全部原始公告开展的事件抽取完整性实验。

节点召回率能够反映事件是否完整，却无法单独评价事件簇的边界。因此，实验同时检查聚类成对 F1、日期顺序、知识截止日、事件阶段一致性和显式因果关系的来源支持。聚类评价将任意两个事件视为一个事件对：系统结果与外部参考划分均将其归入同一事件簇时计为真正例，据此得到事件对精确率 P_{pair} 和召回率 R_{pair} ，并计算：

$$F1_{\text{pair}} = \frac{2P_{\text{pair}}R_{\text{pair}}}{P_{\text{pair}} + R_{\text{pair}}}.$$

该指标同时惩罚错误合并和错误拆分。事件先后顺序与来源证据相反、将后续事件写为前因、混淆事件阶段或使用截止日后信息，均视为明显逻辑断裂，并在结果中单独统计。

5.3.3 专项实验结果与工具性能

工具执行效率从工具接收到已校验参数开始计时，到完整结构化结果返回为止，包含数据库查询、图搜索、计算和结果组装，不包含规划、最终答案生成和前端渲染。各工具操作在预热后至少运行 30 次，使用 P_{95} 延迟判断是否满足 5 秒的竞赛要求。

股权穿透实验按路径深度分为两组：深度等于 3 层的路径作为中等深度对照组，深度大于 3 层的路径用于检验竞赛要求。后者从 4 至 6 层候选路径中分层抽样。每个案例的起止主体、路径方向、每一跳主体、持股比例和累计比例全部正确时，才计为严格通过。

表 13 股权穿透专项结果

专项	样本数	严格通过数	完整严格准确率	P_{95} 延迟
深度等于 3 的持股穿透路径	30	30	100.00%	0.321 秒
深度大于 3 的持股穿透路径	30	30	100.00%	0.336 秒

事件实验分别报告关键节点检索与事件聚类的结果。事件查询以节点召回率为核心指标，事件聚类以聚类成对 F1 为核心指标，两类操作均记录 P_{95} 延迟。

表 14 事件脉络专项结果

专项	样本数	关键节点召回率	聚类成对精确率	聚类成对召回率	聚类成对 F1	P_{95} 延迟
事件查询	30	100.00%	/	/	/	0.008 秒
事件聚类	30	100.00%	93.13%	32.34%	48.00%	0.007 秒

深度等于 3 层和深度大于 3 层的股权穿透实验各纳入 30 个现有案例，后者包含 4 层、5 层和 6 层路径各 10 个。两组共 60 次工具调用均正常完成， P_{95} 延迟分别为 0.321 秒和 0.336 秒。评测程序从原始快照独立重建参考路径，逐项核对路径数量、节点、方向、每跳比例、累计比例、日期和证据标识；60 例确定性比较全部通过。固定版本大模型进一步复核主体同一性、关系语义和来源支持，两组也均为 30 例通过，完整严格准确率均为 100.00%。该结果说明工具在当前冻结主要股东快照和已确认主体桥接覆盖范围内能够稳定复现可证明路径，不代表未披露工商关系或非前十大股东关系也被完整覆盖。

事件查询与事件聚类分别完成 30 次受控调用， P_{95} 延迟分别为 0.008 秒和 0.007 秒。外部评审共确认 117 个关键节点，系统全部保留，关键节点召回率为 100.00%。聚类成对精确率为 93.13%，召回率为 32.34%，F1 为 48.00%。较高的精确率表明不同事件被错误合并的情况较少，较低的召回率则说明同一事件的发展记录经常被拆分到多个小簇，当前聚类规则偏保守。30 个案例均未发现严重时序断裂或知识截止日违规。本批次没有生成显式事件关系，因此无证据因果关系计数为 0，但该结果不能用于证明因果关系识别能力已经得到验证。

5.4 财务风险预警与报告质量

财务风险样本中，未触发风险的情形通常多于触发风险的情形，单独使用准确率容易被多数类掩盖。为同时约束误报与漏报，本实验采用 F1 作为风险预警的核心指标，并分别报告精确率和召回率。样本以“公司、目标报告期、风险类型”为最小单位，参考标签由固定版本外部金融评审模型依据冻结财务记录、规则适用条件和截止日前证据独立复算，只描述可观察的风险信号，不将规则命中直接解释为财务造假。

财务风险预警的精确率、召回率和 F1 定义为：

$$P_{\text{risk}} = \frac{TP_{\text{risk}}}{TP_{\text{risk}} + FP_{\text{risk}}}, \quad R_{\text{risk}} = \frac{TP_{\text{risk}}}{TP_{\text{risk}} + FN_{\text{risk}}},$$

$$F1_{\text{risk}} = \frac{2P_{\text{risk}}R_{\text{risk}}}{P_{\text{risk}} + R_{\text{risk}}}.$$

其中， TP_{risk} 表示系统与外部参考标签均判定存在该类风险信号的样本数， FP_{risk} 表示系统触发但外部参考标签为负的样本数， FN_{risk} 表示外部参考标签为正但系统未触发的样本数。精确率反映误报程度，召回率反映漏报程度，F1 是二者的调和平均值；只有同时减少误报和漏报，F1 才会提高。

真正例、假正例和假负例由工具输出与外部参考标签逐项比对获得。数据不足和规则无法适用的样本单独核验状态识别，不进入风险正负样本分母；数据足以形成正向参考标签而系统未覆盖相应风险类型时计为假负例（FN）。正式结果采用冻结风险类型全集上的微平均 F1，使每个样本对总体结果具有相同权重；各风险类型的精确率、召回率和 F1 用于呈现不同规则的性能差异。

规则命中正确并不意味着最终报告具有实际使用价值，报告还需要准确引用数据、解释指标关系并保持审慎的风险措辞。因此，财务排雷报告采用固定版本外部金融评审模型实施代理盲评，与确定性规则的 F1 形成互补。评审从数据与引用、逻辑自洽、金融专业性、完整与可用性四个维度评分，每项采用 1 至 5 分。四个维度均不低于 4 分、平均分不低于 4.0，且不存在核心事实错误、虚假引用、截止日泄露或直接定性造假时，报告判定为优秀。该结果用于统一口径下的批量比较，正式专家验收仍应由具备财务、审计或证券研究背景的人员复核。

完成评分后，代理盲评优秀率按下式计算：

$$E_{report} = \frac{N_{excellent}}{N_{valid}}.$$

其中， N_{valid} 为完成盲评且不存在样本损坏等排除情形的报告总数， $N_{excellent}$ 为同时满足四项评分门槛且不存在否决性错误的报告数。该指标将多维评分转化为报告级验收结果，避免单项高分掩盖核心事实错误或虚假引用。

财务风险结果按风险类型分别报告正负样本规模、精确率、召回率和 F1，并使用微平均结果反映整体预警能力。报告质量通过代理评审的评分均值、评分离散程度、优秀占比和否决性错误数量进行评价。

风险预警实验从全量问答批次中取得 24 次已完成的财务风险扫描，按实际执行规则展开为 179 个“公司一期间一风险类型”判断。其中 166 个样本具备完整指标并能够形成正负参考标签，包括正样本 68 个、负样本 98 个；另有 13 个样本因数据不足或规则无法适用而排除在正负分类指标之外。系统在 166 个有效样本上未出现误报或漏报，总体精确率、召回率和微平均 F1 均为 100.00%。外部金融评审依据冻结财务指标、规则适用条件、计算公式和阈值独立复算参考标签，未接触系统原判定。

该结果表明风险扫描工具能够按照既定规则稳定复现跨期勾稽结果，但其评价边界是规则计算一致性，不等同于利用真实财务造假结果检验预测能力。经营现金流持续为负等规则所需字段较少，执行条件相对稳定；利润与现金流、存货与收入、应收账款与收入等跨期规则依赖连续可比期间，数据不足时会进入不可评价状态；利润率、流动性和杠杆规则仍可能受到行业差异及初始阈值适用范围的影响。因此，实验可以验证现有规则实现及证据链是否正确，**不能据此声称已**

表 15 分类型财务风险识别结果

风险类型	正样本	负样本	精确率	召回率	F1
利润与经营现金流背离	11	5	100.00%	100.00%	100.00%
存货与收入背离	10	9	100.00%	100.00%	100.00%
应收账款与收入背离	4	16	100.00%	100.00%	100.00%
经营现金流持续为负	2	20	100.00%	100.00%	100.00%
销售收现与收入背离	10	12	100.00%	100.00%	100.00%
利润率异常变化	13	10	100.00%	100.00%	100.00%
流动性与杠杆压力	18	26	100.00%	100.00%	100.00%
总体微平均	68	98	100.00%	100.00%	100.00%

经覆盖所有财务舞弊模式。

在风险识别结果的基础上，代理盲评进一步检验报告能否把指标、证据和风险解释组织成完整研判。除严格优秀率外，实验同时报告无否决性错误率，以区分“内容不够完整”与“存在严重事实或证据错误”。

表 16 财务报告质量评价结果

报告质量指标	平均分	标准差	达标占比	否决性错误数量
数据与引用	3.92	1.11	58.33%	0
逻辑自洽	3.92	0.57	79.17%	0
金融专业性	4.21	0.50	95.83%	0
完整与可用性	2.75	0.66	12.50%	0
无否决性错误率	/	/	100.00%	0
总体优秀率	/	/	12.50%	0

有效盲评报告共 24 份，其中优秀报告 3 份，优秀率为 12.50%，未发现核心事实错误、无依据引用、知识截止日违规或直接定性造假等否决性错误。金融专业性平均得分最高，说明报告能够较好地区分风险信号与确定事实，并保持审慎措辞；逻辑自洽和数据引用总体接近良好水平，但不同案例之间仍有较明显差异。完整与可用性平均得分仅为 2.75，是优秀率偏低的主要原因。现有回答大多以部分回答状态结束，面对“基本面怎么样”“有哪些风险”等宽泛问题时，往往只解释部分已取得证据，没有充分覆盖主要风险信号、跨工具信息及其对用户问题的综合含义。因而，后续改进重点不在增加结论强度，而在保证核心风险覆盖、组织跨工具证据，并明确区分已验证信息、数据缺口和进一步核查方向。

财务专项的运行效率分为两个环节记录。风险扫描是确定性计算过程，统计数据查询与规则计算耗时；报告生成依赖大模型，除延迟外还记录输入输出 Token 和调用成本。失败原因按指标数据、报告期口径、风险规则、证据引用和报告生成分类，用于解释异常耗时和报告质量变化。

表 17 财务专项运行效率

环节	样本数	P ₅₀ 延迟	P ₉₅ 延迟	最大延迟	平均 Token
风险扫描	24	0.007 秒	0.020 秒	0.024 秒	/
财务报告生成	24	52.67 秒	66.75 秒	67.73 秒	7,604.08

在全量问答评测产生的 24 次财务风险分析中，风险扫描和财务报告生成的 P₉₅ 延迟分别为 0.020 秒和 66.75 秒，报告平均消耗 7,604.08 Tokens。风险扫描在本地完成数据查询和规则计算，耗时较低且波动较小；报告生成需要组织多条证据并调用主模型，是财务专项更主要的延迟来源。上述结果用于描述实际运行效率，不替代风险预警 F1 和报告质量复核；单份平均成本将在按照实际计费单价折算后补充。

5.5 综合分析 with 本章小结

前述实验分别检验了 FinTrace 的多轮问答与工具路由、股权和事件专项工具，以及财务风险识别与报告生成能力。将这些结果放回竞赛验收框架，可以更清楚地判断系统已经形成的能力、尚未达到的指标及其改进方向。下表沿用各分项实验的样本范围和计算口径，对九项技术要求进行统一对照。

九项技术要求中，五项已经达到当前验收目标，两项未达到，另有两项因 0.5M Tokens 专项压力实验尚未开展而暂不形成结论。现有 1,410 轮实验说明，分层记忆、实体解析和时间约束能够支持常规多轮任务，但实际单轮最高 Token 总量为 116,283，不能据此推断极限上下文条件下的回答准确率和事实召回率。工具轮次级路由正确率为 91.70%，距离 92% 的目标相差 0.30 个百分点；相比之下，真实运行错误的自动处置率达到 92.52%，说明系统在参数修复、重新规划和安全终止方面已有较稳定表现。下一阶段需要优先减少复杂调查中的必要工具遗漏和关键参数错配，而不是继续增加额外调用。

专项工具的优势主要体现在确定性计算和执行效率。深度大于 3 层的股权穿透案例全部严格通过，股权与事件工具的 P₉₅ 延迟也均低于 5 秒。事件实验则呈现出更具体的改进信号：索引内关键节点全部得到保留，且未发现严重时序断裂，但聚类成对 F1 仅为 48.00%，说明系统倾向于将同一事件链拆分为多个小簇。后续应重点加强公告文号、涉及主体、事件阶段和主题特征的联合匹配。上述结果仅覆盖前十大股东快照、已确认主体桥接和既有事件索引，不能外推到未披露工商关系、非主要股东关系或尚未抽取的原始公告。

财务实验进一步说明了“工具正确”与“报告优秀”之间的差距。风险扫描在既定规则范围

表 18 竞赛技术要求综合验收结果

竞赛技术要求	实验结果	验收目标	结论
0.5M Tokens、10 轮以上问答准确率	/	≥90%	—
0.5M Tokens、10 轮以上事实召回率	/	≥90%	—
外部工具轮次级路由正确率	91.70%	≥92%	×
轨迹错误自动处置率（自纠错成功率）	92.52%	≥80%	✓
深度大于 3 层的股权穿透完整严格准确率	100.00%	≥85%	✓
事件关键节点召回及因果、时序一致性	100.00%；无严重断裂	召回率 ≥85%；无逻辑断裂	✓
股权穿透与事件脉络工具执行时间	0.336 秒；0.008 秒	≤5 秒	✓
财务风险预警微平均 F1	100.00%	≥85%	✓
财务排雷报告优秀率（代理盲评）	12.50%	≥80%	×

内实现 100.00% 的微平均 F1，表明跨科目计算、适用条件和证据关联能够稳定复现；这一结果验证的是规则实现一致性，并非真实财务造假预测率。报告代理盲评未发现核心事实错误、无依据引用或越过风险语义边界等否决性问题，但严格优秀率只有 12.50%，主要受完整与可用性不足影响。系统下一步需要把已经获得的结构化信号转化为覆盖充分、层次清楚的研判，同时补充现有三大报数据尚不能支持的关联交易、异常费用和汇兑风险边界。

综合来看，FinTrace 已经建立了可追踪的多轮工作流、低延迟的确定性专项工具和具备证据约束的财务风险扫描。当前短板也较为集中：0.5M Tokens 条件缺少直接验证，工具路由仍有少量必要调用遗漏，事件聚类偏保守，最终财务报告的内容覆盖不足。后续工作应围绕这四项问题开展针对性实验和迭代，并继续保留主体、期间、证据与知识截止日的结构化审计记录，使性能提升能够被同一套评测口径复核。

6 工程落地与展望

FinTrace 的工程实现以可运行、可复现和可扩展为核心原则。项目采用模块化 Python 架构，将用户入口、Agent Harness、金融工具、数据处理、Prompt 管理、评测与部署各层解耦，使单个模块能够独立测试与替换，降低系统演化成本。

6.1 工程实现与部署

系统同时支持本地 CLI 与 FastAPI 两种部署形态。CLI 可直接调用核心 `run_agent()` 接口，适用于开发调试与现场演示；FastAPI 将同一 Agent 封装为标准化 HTTP 服务，便于 Web 前端或外部系统集成调用。模型接口采用 OpenAI-compatible 协议封装，Prompt 则按请求解析、动作规划、证据审查、动作修复与最终生成等职责进行版本化管理。

表 19 FinTrace 主要工程组件

组件	主要用途
LangGraph	Agent 状态流转、条件分支与有界调查控制
Pydantic	请求、Action、ToolResult、Evidence 等数据契约定义
SQLite / FAISS / BM25	结构化查询、向量检索与关键词检索
NetworkX	关系图构建与路径分析
FastAPI / Uvicorn	标准化 HTTP 服务接口
PyMuPDF / python-docx	公告与报告等文档解析处理
Pytest	工具单元测试、工作流验证与回归测试

6.2 应用与落地可行性

FinTrace 不依赖专用金融大模型的重新训练，而是利用通用模型完成语义理解、调查决策与解释生成，将财务计算、关系搜索与时间过滤交由确定性工具执行，从而以较低训练成本实现持续迭代。数据、工具与模型均通过统一 Schema 解耦，后续可逐步替换数据源 Embedding 模型、语言模型或检索索引，具备良好的可演进性。

面向个人投资者，系统可用于公司事实查证、风险线索整理与研究辅助；面向专业场景，可进一步接入授权金融数据库、内部研究资料与更完整的知识图谱。应用层可以扩展，但核心边界保持不变：模型负责组织研究过程，关键金融事实必须由工具产出并由 Evidence 支持。

6.3 局限性与未来工作

当前系统仍受数据覆盖范围与研究边界制约。公开主要股东数据尚不足以独立还原全部实际控制关系；实时行情、宏观指标与完整新闻舆情仍需外部接口补充；长期记忆机制与复杂调查策略有待在更大规模真实会话中持续验证；财务风险规则仅能提供进一步核查线索，不能替代审计结论或投资决策。

后续工作将聚焦以下方向：扩展实时金融 API 与新闻舆情接入、补充非上市主体及控制关系数据、完善跨 Session 长期研究记忆机制，并加强 Claim 级别的自动核验与来源冲突检测。

6.4 结论

本文提出 FinTrace，一套面向上市公司研究的证据驱动型可追溯金融智能体。系统通过可回答性 Gate、确定性快速路径与有界调查机制，将多源金融数据、专业工具与 Evidence Ledger 组织为可执行、可验证且可审计的研究过程。

FinTrace 的目标并非让大模型记忆更多金融事实，而是使其在明确的能力边界内选择正确的调查动作，并让最终结论始终受数据、时间与证据约束。随着评测体系、实时数据接入与关系图谱的进一步完善，该架构可继续扩展为面向个人投资者与研究人员的可信金融研究辅助系统。